

BAHAN PERSIAPAN BIMBINGAN SKRIPSI

Dave Tjong | 2602077736 | Computer Science

Dosen Pembimbing: Derwin Suhartono

Judul Penelitian

Secure Gait-Based Authentication Using Explainable Federated Learning (Autentikasi Aman Berbasis Pola Berjalan Menggunakan Explainable Federated Learning)

Dokumen ini berisi: Ringkasan Proposal | Justifikasi Keputusan Teknis | Glosarium | Perkiraan Pertanyaan Dosen

BAGIAN 1 — RINGKASAN PROPOSAL

1.1 Inti Masalah (The "Why")

Metode autentikasi yang ada saat ini menghadapi dua ancaman besar yang belum tertangani secara bersamaan:

- **Keamanan:** Password bisa dicuri, wajah dan suara bisa dipalsukan oleh AI generatif (deepfake). Biometrik statis semakin tidak aman.
- **Privasi:** Sistem biometrik berbasis cloud mengharuskan data sensitif pengguna dikirim ke server pusat, menciptakan risiko kebocoran data.
- **Interpretabilitas:** Model deep learning bersifat black-box, sehingga tidak ada cara untuk membuktikan bahwa model belajar dari karakteristik biologis yang benar, bukan dari noise atau artefak data.

Gait (pola berjalan) sebagai biometrik menawarkan jawaban atas masalah keamanan karena sulit dipalsukan. Namun, dua masalah berikutnya (privasi dan interpretabilitas) belum pernah diselesaikan secara terintegrasi dalam satu sistem.

1.2 Solusi yang Diusulkan (The "What")

Satu Kalimat Inti

Penelitian ini membangun sistem yang mengautentikasi pengguna berdasarkan cara berjalan mereka (gait), melatih modelnya tanpa mengirim data ke server (Federated Learning), dan menjelaskan alasan keputusan model menggunakan SHAP (Explainable AI).

Tiga komponen yang diintegrasikan:

- **Gait Authentication:** menggunakan accelerometer dan gyroscope smartphone untuk mengenali cara berjalan sebagai biometrik.
- **Federated Learning (FedAvg):** melatih model secara terdistribusi di perangkat masing-masing pengguna. Data mentah tidak pernah meninggalkan perangkat.
- **Explainable AI (SHAP):** menjelaskan fitur sensor mana yang paling berkontribusi pada keputusan model, dan memvalidasi bahwa model belajar dari karakteristik gait yang nyata.

1.3 Research Questions dan Hipotesis

RQ1 (Efektivitas): Seberapa efektif gait sebagai biometrik? Target: EER < 5%, Accuracy > 90%.

RQ2 (Trade-off): Seberapa besar penurunan performa akibat Federated Learning dibanding training terpusat? Target: degradasi < 5 poin persentase.

RQ3 (Explainability): Apakah SHAP mengidentifikasi fitur yang sesuai ekspektasi biomekanika gait? Target: Spearman rho antara importance model centralized vs federated $\geq 0,70$.

1.4 Metodologi Singkat

Data dikumpulkan dari 50–100 partisipan menggunakan aplikasi Android (accelerometer + gyroscope, 50 Hz, 4 posisi smartphone). Setelah preprocessing (filter + windowing 2,56 detik + normalisasi), model CNN-LSTM dilatih dalam dua cara: terpusat (Skenario 1) dan federated (Skenario 2–4). Hasilnya dianalisis dengan SHAP dan diuji secara statistik (t-test + Spearman).

1.5 Kontribusi Ilmiah (Novelty)

Novelty Utama

Mayoritas penelitian sebelumnya hanya menggabungkan dua dari tiga komponen ini: (1) gait + FL tanpa XAI, atau (2) gait + XAI tanpa FL. Penelitian ini adalah salah satu yang pertama mengintegrasikan ketiganya dalam satu sistem evaluasi yang komprehensif dengan dataset yang dikumpulkan sendiri.

BAGIAN 2 — JUSTIFIKASI KEPUTUSAN TEKNIS

Setiap angka dan pilihan metode dalam proposal bukan arbitrer. Berikut alasan di balik setiap keputusan, disertai referensi pendukung.

2.1 Pemilihan Gait sebagai Biometrik

Keputusan

Menggunakan gait (pola berjalan) dari sensor inersial smartphone, bukan biometrik lain.

- **Gait dihasilkan oleh kombinasi struktur muskuloskeletal, distribusi berat badan, dan kebiasaan motorik yang unik.** Deepfake AI saat ini tidak dapat mensimulasikan gait secara meyakinkan karena memerlukan pemahaman fisika tubuh yang sangat kompleks (Khaund et al., 2025). Alasan 1 – Ketahanan terhadap deepfake:
- **Pengguna tidak perlu melakukan tindakan khusus (berbeda dengan sidik jari atau face ID).** Ini membuka kemungkinan autentikasi yang tidak mengganggu pengalaman pengguna. Alasan 2 – Passive & continuous:
- **Tidak memerlukan hardware tambahan, sehingga skalabel untuk deployment massal.** Alasan 3 – Sensor sudah ada di smartphone:
- **Gait bersifat behavioral (perilaku), bukan fisiologis statis.** Karakteristik perilaku lebih sulit ditiru karena bergantung pada pola gerak yang telah terbentuk bertahun-tahun. Alasan 4 – Diferensiasi dari biometrik statis:

2.2 Pemilihan Arsitektur CNN-LSTM

Keputusan

Menggunakan hybrid CNN-LSTM, bukan CNN saja, LSTM saja, atau Transformer.

- **Sinyal gait memiliki pola lokal yang berulang (misalnya, spike pada setiap pendaratan kaki).** Conv1D sangat efisien untuk mendeteksi pola lokal dalam sinyal time-series. Mengapa CNN:
- **Siklus gait adalah urutan temporal dengan dependensi jangka panjang (heel strike, mid-stance, toe-off).** LSTM menangkap "memori" urutan ini yang tidak bisa ditangkap CNN saja. Mengapa LSTM:
- **Transformer memerlukan lebih banyak data dan komputasi untuk konvergensi.** Untuk skripsi S1 dengan dataset 50–100 partisipan, CNN-LSTM lebih stabil dan terbukti dalam literatur (Choi et al., 2023; He et al., 2022). Mengapa bukan Transformer:
- **He et al. (2022) menggunakan Conv1D untuk gait dan mencapai hasil yang baik.** Choi et al. (2023) dengan CNN mencapai accuracy 91,76% pada 10 partisipan. Referensi pendukung:

2.3 Pemilihan Sampling Rate 50 Hz

Keputusan

Menggunakan sampling rate 50 Hz untuk sensor.

- **Komponen frekuensi utama gait manusia berada di bawah 20 Hz (frekuensi langkah $\sim 1\text{--}3$ Hz, harmonik hingga ~ 20 Hz). Berdasarkan teorema Nyquist, sampling rate minimum harus $2 \times$ frekuensi tertinggi = 40 Hz. Kita pilih 50 Hz untuk memberikan margin keamanan. Alasan Nyquist:**
- **50 Hz adalah sampling rate standar yang digunakan dalam mayoritas penelitian gait berbasis IMU (Cola et al., 2016; He et al., 2022), sehingga hasil kita dapat dibandingkan secara langsung. Alasan praktis:**
- **Sampling rate yang lebih tinggi (100 Hz, 200 Hz) tidak memberikan informasi tambahan yang bermakna untuk gait, tetapi meningkatkan ukuran data dan biaya komputasi. Trade-off:**

2.4 Pemilihan Window Size 128 Samples (2,56 Detik)

Keputusan

Window size 128 samples = 2,56 detik pada 50 Hz, dengan overlap 50%.

- **Satu siklus gait penuh (dari heel strike kaki kiri ke heel strike kaki kiri berikutnya) berlangsung sekitar 1,0–1,4 detik pada kecepatan normal. Window 2,56 detik mencakup 1–2 siklus gait penuh, cukup untuk mengekstraksi pola yang representatif. Alasan biomekanika:**
- **He et al. (2022) dan Choi et al. (2023) menggunakan window dalam rentang 2–3 detik dan mendapatkan hasil yang baik. Ini adalah ukuran yang sudah tervalidasi dalam literatur. Alasan referensi:**
- **Overlap meningkatkan jumlah training sample tanpa memerlukan lebih banyak partisipan, dan memastikan tidak ada informasi gait yang "jatuh di batas" window. Alasan overlap 50%:**

2.5 Pemilihan Butterworth Filter Cutoff 20 Hz

Keputusan

Low-pass Butterworth filter dengan cutoff frequency 20 Hz, order 4.

- **Informasi gait yang relevan berada di bawah 20 Hz. Frekuensi di atas 20 Hz adalah noise elektronik dari sensor (vibration, electrical noise) yang justru akan menyesatkan model. Alasan cutoff 20 Hz:**
- **Butterworth filter memiliki respons frekuensi yang flat di passband (tidak mengubah amplitudo sinyal yang diperlukan) dan roll-off yang smooth, cocok untuk preprocessing biometrik. Alasan Butterworth:**
- **Order 4 memberikan atenuasi yang cukup (-80 dB/decade) tanpa distorsi fase yang berlebihan. Order yang terlalu tinggi menyebabkan ringing artifact. Alasan order 4:**

2.6 Pemilihan Federated Learning (FedAvg)

Keputusan

Menggunakan FedAvg sebagai algoritma FL, bukan FedProx, SCAFFOLD, atau algoritma FL lainnya.

- **FedAvg adalah algoritma FL paling fundamental (McMahan et al., 2017) dan menjadi titik referensi wajib dalam setiap penelitian FL. Tanpa baseline FedAvg, hasil tidak bisa dibandingkan dengan literatur lain. Alasan 1 – Baseline penelitian:**
- **Proposal secara eksplisit menyatakan tidak mengembangkan algoritma FL baru. Fokus penelitian adalah evaluasi integrasi, bukan inovasi algoritma FL. Alasan 2 – Scope penelitian:**
- **Algoritma seperti FedProx atau SCAFFOLD memerlukan tuning tambahan dan pemahaman yang lebih dalam tentang optimasi terdistribusi, yang melampaui scope skripsi ini. Alasan 3 – Kelayakan S1:**
- **Keterbatasan FedAvg pada kondisi non-IID justru menjadi salah satu hal yang dievaluasi dalam Skenario 3, sehingga pemilihan ini konsisten dengan tujuan penelitian. Catatan penting:**

2.7 Pemilihan SHAP (bukan LIME atau Saliency Maps)

Keputusan

Menggunakan SHAP untuk explainability, bukan LIME atau gradient-based saliency.

- **SHAP didasarkan pada Shapley value dari cooperative game theory yang memiliki sifat matematika yang terbukti: efficiency, symmetry, dummy, dan additivity. LIME tidak memiliki jaminan matematika sekuat ini. Alasan 1 – Fondasi matematika:**
- **SHAP menghasilkan penjelasan yang konsisten secara global (pola di seluruh dataset) maupun lokal (per instance). Saliency maps hanya lokal. Alasan 2 – Konsistensi global:**
- **SHAP dapat diterapkan pada model apapun, termasuk hasil agregasi FedAvg yang tidak bisa dianalisis dengan teknik intrinsik model tertentu. Alasan 3 – Model-agnostic:**
- **Library SHAP sangat mature dan sudah digunakan dalam banyak penelitian gait/biometrik (Li et al., 2023), memudahkan validasi dan replikasi. Alasan 4 – Dukungan komunitas:**

2.8 Target Performance: EER < 5% dan Accuracy > 90%

Keputusan

Menetapkan target EER < 5% dan Accuracy > 90% sebagai kriteria keberhasilan H1.

- **Choi et al. (2023) mencapai 91,76% dengan 10 partisipan. He et al. (2022) dengan 21 partisipan juga di atas 90%. Ini menjadi benchmark yang realistis untuk dataset serupa. Dasar penetapan accuracy 90%:**
- **EER adalah metrik standar industri untuk sistem biometrik. EER 5% setara dengan FAR dan FRR masing-masing sebesar 5%, yang dianggap acceptable untuk sistem autentikasi non-kritis. Sistem banking biasanya mensyaratkan EER < 1%, tetapi itu di luar scope penelitian ini. Dasar penetapan EER 5%:**

- Dengan 50–100 partisipan (lebih banyak dari studi referensi), variasi data lebih besar sehingga target yang sama dengan dataset lebih kecil adalah tantangan yang valid. Catatan realistis:

2.9 Jumlah Partisipan: 50–100

Keputusan

Merekrut 50–100 partisipan, bukan lebih sedikit atau lebih banyak.

- Untuk one-sample t-test dengan effect size medium (Cohen's $d = 0,5$), power 80%, dan alpha 5%, minimal diperlukan 50 partisipan agar kesimpulan statistik valid. Ini adalah perhitungan power analysis standar. Batas bawah 50 (power analysis):
- Rekrutmen lebih dari 100 orang untuk skripsi S1 individual dalam timeframe normal tidak realistis. 100 juga memberikan buffer untuk data yang harus dibuang karena kualitas buruk. Batas atas 100 (sumber daya):
- Mayoritas studi serupa menggunakan 10–50 partisipan (Choi: 10, He: 21). Dataset dengan 50+ partisipan sudah jauh lebih robust secara statistik. Perbandingan dengan literatur:

2.10 Simulasi FL (bukan Deployment Fisik)

Keputusan

Mensimulasikan Federated Learning pada satu mesin, bukan deploy ke perangkat fisik yang berbeda.

- Deploy FL ke 50–100 smartphone fisik memerlukan infrastruktur jaringan, manajemen perangkat, dan koordinasi yang jauh melampaui scope skripsi S1. Alasan kelayakan:
- Mayoritas penelitian FL akademis (termasuk paper McMahan et al. asli) menggunakan simulasi pada satu mesin. Ini adalah praktik standar dan diterima oleh komunitas ilmiah. Preseden dalam literatur:
- Simulasi tidak merepresentasikan overhead komunikasi jaringan nyata, variasi perangkat heterogen, atau client yang dropout. Ini harus disebutkan secara eksplisit di bagian keterbatasan. Limitasi yang harus disebutkan:

BAGIAN 3 — GLOSARIUM ISTILAH TEKNIS

Definisi berikut disusun untuk membantu menjelaskan istilah kepada dosen atau audiens yang mungkin tidak familiar dengan semua konsep teknis.

3.1 Konsep Utama Penelitian

Gait Authentication

Proses memverifikasi identitas seseorang berdasarkan pola cara berjalannya. Gait bersifat behavioral biometric, artinya mencerminkan kebiasaan motorik yang telah terbentuk bertahun-tahun dan sangat sulit ditiru. Sensor yang digunakan adalah accelerometer (mengukur percepatan linear) dan gyroscope (mengukur kecepatan rotasi) pada smartphone.

Relevansi ke penelitian ini: *Ini adalah "produk" yang dibangun dalam penelitian ini.*

Explicit Gait Verification

Sistem yang secara aktif menggunakan periode berjalan tertentu sebagai momen autentikasi. Berbeda dari implicit yang memonitor gait terus-menerus di background. Pada sistem eksplisit, pengguna diminta berjalan beberapa langkah untuk diverifikasi, kemudian sistem memberikan keputusan akses.

Relevansi ke penelitian ini: *Membedakan pendekatan penelitian ini dari sistem continuous authentication.*

Biometrik Statis vs Biometrik Behavioral

Biometrik statis adalah karakteristik fisik yang tidak berubah: sidik jari, iris mata, geometri wajah. Biometrik behavioral adalah karakteristik cara seseorang melakukan sesuatu: cara berjalan, cara mengetik, cara menulis. Biometrik behavioral umumnya lebih sulit dipalsukan tetapi memiliki variabilitas alami yang lebih tinggi.

Relevansi ke penelitian ini: *Gait adalah biometrik behavioral, yang menjadi keunggulan dan tantangan sekaligus.*

Equal Error Rate (EER)

Titik di mana False Acceptance Rate (FAR) = False Rejection Rate (FRR). FAR adalah persentase impostor yang salah diterima sebagai genuine. FRR adalah persentase genuine yang salah ditolak. EER yang lebih rendah berarti sistem lebih akurat. EER 0% berarti sempurna (tidak ada error), EER 50% berarti acak seperti coin flip.

Relevansi ke penelitian ini: *Metrik utama untuk mengukur keberhasilan sistem autentikasi (H1).*

Federated Learning (FL)

Paradigma machine learning di mana model dilatih secara terdistribusi di banyak perangkat (client) tanpa data mentah dikirim ke server pusat. Setiap client melatih model lokal menggunakan datanya sendiri, lalu hanya mengirimkan parameter model (bobot/gradient) ke server. Server mengagregasi parameter ini menjadi model global yang lebih baik. Proses ini diulang dalam beberapa communication rounds.

Relevansi ke penelitian ini: *Solusi utama untuk masalah privasi: data biometrik tidak pernah meninggalkan perangkat pengguna.*

FedAvg (Federated Averaging)

Algoritma agregasi FL yang paling umum, diperkenalkan oleh McMahan et al. (2017). Setelah setiap round, server menghitung rata-rata tertimbang dari semua parameter model lokal yang diterima, di mana bobotnya proporsional terhadap jumlah data lokal masing-masing client. Model global yang dihasilkan kemudian dikirim kembali ke semua client sebagai titik awal round berikutnya.

Relevansi ke penelitian ini: *Algoritma FL yang diimplementasikan dalam penelitian ini.*

Non-IID (Non-Independently and Identically Distributed)

Kondisi di mana distribusi data berbeda-beda antar client dalam FL. Dalam konteks gait, ini terjadi secara alami karena setiap orang memiliki pola berjalan yang berbeda. Non-IID adalah tantangan utama FL karena model lokal yang dioptimalkan untuk data satu client mungkin kurang cocok untuk data client lain, sehingga agregasi menjadi lebih sulit.

Relevansi ke penelitian ini: *Disimulasikan menggunakan Dirichlet distribution dalam Skenario 3.*

Dirichlet Distribution

Distribusi probabilitas yang digunakan untuk mengontrol tingkat heterogenitas data dalam simulasi FL. Parameter konsentrasi alpha mengontrol seberapa merata distribusi data antar client: alpha sangat besar (misal 1000) = IID (distribusi merata), alpha kecil (misal 0,1) = sangat non-IID (beberapa client mendapat hampir semua data dari satu kelas).

Relevansi ke penelitian ini: *Digunakan untuk mensimulasikan berbagai tingkat non-IID dalam Skenario 3.*

Explainable AI (XAI)

Bidang AI yang berfokus pada membuat keputusan model AI dapat dipahami oleh manusia. Penting untuk membangun kepercayaan, melakukan debugging, dan memenuhi regulasi. Dalam konteks biometrik, XAI digunakan untuk memverifikasi bahwa model menggunakan fitur yang benar-benar bermakna secara biologis.

Relevansi ke penelitian ini: *Komponen ketiga dari sistem yang dibangun, menjawab RQ3.*

SHAP (SHapley Additive exPlanations)

Metode XAI yang menghitung kontribusi setiap fitur terhadap prediksi model menggunakan konsep Shapley value dari teori permainan kooperatif. SHAP menjawab pertanyaan: "Berapa besar kontribusi fitur ke-i terhadap prediksi ini dibandingkan rata-rata semua prediksi?" Nilai SHAP positif berarti fitur tersebut mendorong prediksi ke arah "genuine", negatif berarti mendorong ke "impostor".

Relevansi ke penelitian ini: *Diterapkan pada model global FedAvg untuk validasi H3.*

3.2 Konsep Preprocessing dan Model

Accelerometer

Sensor yang mengukur percepatan linear (perubahan kecepatan) dalam tiga arah: x (kiri-kanan), y (atas-bawah), z (depan-belakang). Satuan: m/s^2 . Dalam gait, accelerometer menangkap gerakan tubuh saat melangkah, terutama guncangan vertikal (acc_y) saat kaki mendarat.

Relevansi ke penelitian ini: *Salah satu dari dua sensor utama yang digunakan untuk merekam data gait.*

Gyroscope

Sensor yang mengukur kecepatan angular (kecepatan rotasi) dalam tiga sumbu: x (pitch, anggukan kepala), y (yaw, gerak memutar), z (roll, miring ke samping). Satuan: rad/s. Dalam gait, gyroscope menangkap rotasi tubuh saat berjalan, terutama gyr_z yang merepresentasikan ayunan tubuh secara lateral.

Relevansi ke penelitian ini: *Sensor kedua yang digunakan bersama accelerometer untuk merekam data gait (6 channel total).*

Sliding Window

Teknik segmentasi sinyal time-series menjadi potongan-potongan pendek yang overlapping. Window berukuran W samples digeser sebesar S samples (step) setiap iterasi. Window 128 samples dengan step 64 (overlap 50%) berarti setiap window kedua berbagi 64 samples dengan window sebelumnya. Ini menghasilkan lebih banyak training samples dari sinyal yang sama.

Relevansi ke penelitian ini: *Menghasilkan input tensor (N_windows, 128, 6) dari sinyal gait mentah.*

Z-Score Normalization

Transformasi data agar memiliki mean = 0 dan standar deviasi = 1. Formula: $x_{norm} = (x - mean) / std$. Dilakukan per sensor axis. Penting agar model tidak bias terhadap skala nilai sensor yang berbeda-beda. Scaler di-fit HANYA pada training data, kemudian diterapkan ke validation dan test data dengan parameter yang sama.

Relevansi ke penelitian ini: *Mencegah data leakage: informasi statistik dari test set tidak boleh digunakan saat training.*

Butterworth Filter

Filter low-pass yang menghilangkan komponen frekuensi tinggi dari sinyal. "Low-pass" berarti frekuensi rendah (di bawah cutoff) dibiarkan lewat, frekuensi tinggi (di atas cutoff) diblokir. Butterworth dipilih karena memiliki respons yang rata di passband (tidak mengubah amplitudo sinyal yang diperlukan). `filtfilt()` digunakan untuk zero-phase filtering, artinya tidak menggeser sinyal dalam domain waktu.

Relevansi ke penelitian ini: *Menghilangkan electrical noise dari sensor sebelum segmentasi.*

CNN (Convolutional Neural Network)

Jaringan saraf yang menggunakan operasi konvolusi untuk mendeteksi pola lokal. Conv1D memindahkan filter berukuran kecil (kernel) sepanjang dimensi waktu untuk mencari pola yang berulang. Setiap filter

belajar untuk mendeteksi satu jenis pola tertentu (misalnya, spike saat heel strike). Batch Normalization mempercepat training dan mengurangi overfitting.

Relevansi ke penelitian ini: *Lapisan pertama model: mengekstraksi fitur spasial/lokal dari sinyal gait.*

LSTM (Long Short-Term Memory)

Jenis Recurrent Neural Network yang dirancang khusus untuk mengatasi vanishing gradient problem, sehingga mampu mengingat dependensi jangka panjang dalam urutan data. LSTM memiliki tiga gate: forget gate (informasi mana yang dilupakan), input gate (informasi baru mana yang disimpan), output gate (informasi mana yang dikeluarkan). Dalam gait, LSTM mengingat urutan fase berjalan.

Relevansi ke penelitian ini: *Lapisan kedua model: menangkap dependensi temporal dalam sinyal gait.*

Spearman Rank Correlation

Ukuran korelasi antara dua variabel berdasarkan ranking, bukan nilai absolutnya. Berbeda dari Pearson correlation yang mengasumsikan hubungan linear. Spearman mengukur apakah satu variabel cenderung meningkat ketika variabel lain meningkat, tanpa asumsi tentang bentuk hubungannya. Nilai rho berkisar dari -1 (anti-korelasi sempurna) hingga +1 (korelasi sempurna).

Relevansi ke penelitian ini: *Digunakan untuk mengukur apakah urutan kepentingan fitur SHAP antara model centralized dan federated konsisten (H3).*

BAGIAN 4 — KEMUNGKINAN PERTANYAAN DOSEN

Cara Menggunakan Bagian Ini

Baca jawaban yang direkomendasikan dengan suara keras sebelum bimbingan. Jangan hafalkan kata per kata, tapi pastikan Anda memahami logika di balik setiap jawaban. Jika dosen bertanya hal yang tidak ada di sini, tenang dan jujur: "Poin yang bagus, Pak/Bu, saya akan perkuat bagian itu."

4.1 Pertanyaan tentang Novelty dan Kontribusi

Pertanyaan Dosen: *"Apa yang membedakan penelitian ini dari penelitian gait authentication yang sudah ada sebelumnya?"*

Jawaban yang Direkomendasikan:

Penelitian ini mengintegrasikan tiga komponen secara bersamaan: gait authentication, Federated Learning, dan Explainable AI dalam satu sistem evaluasi. Studi sebelumnya seperti Choi et al. (2023) hanya melakukan gait authentication tanpa FL maupun XAI. Zhang et al. (2022) menggabungkan gait dan FL tetapi tidak ada komponen explainability. Survey Swaroopa Rani (2025) menemukan gap ini secara eksplisit: mayoritas studi menggabungkan dua dari tiga, bukan ketiganya. Selain itu, kami menggunakan dataset yang dikumpulkan sendiri dengan variasi posisi smartphone yang lebih representatif.

Tips: *Siapkan slide atau diagram yang menunjukkan gap ini dalam tabel perbandingan dengan studi-studi terkait.*

Pertanyaan Dosen: *"Apakah ini penelitian yang cukup signifikan untuk level skripsi? Apakah terlalu ambisius?"*

Jawaban yang Direkomendasikan:

Penelitian ini dirancang sebagai proof-of-concept yang fokus pada evaluasi integrasi, bukan pengembangan algoritma baru dari nol. Setiap komponen (gait auth, FL, SHAP) sudah ada sebagai library dan framework yang mature. Kontribusi penelitian ini adalah pada evaluasi empiris dan validasi integrasi, yang memang berada dalam scope yang tepat untuk skripsi S1. Skripsi ini menjawab satu pertanyaan konkret: apakah ketiga komponen ini bisa bekerja bersama dengan performa yang acceptable?

Tips: *Sampaikan dengan percaya diri bahwa ruang lingkup sudah dibatasi secara eksplisit di Bab 1.4.*

4.2 Pertanyaan tentang Metodologi

Pertanyaan Dosen: *"Mengapa tidak menggunakan arsitektur yang lebih modern seperti Transformer atau Vision Transformer untuk sinyal gait?"*

Jawaban yang Direkomendasikan:

Transformer memerlukan lebih banyak data untuk mencapai performa yang baik dan cenderung overfitting pada dataset kecil. Dengan 50–100 partisipan, yang menghasilkan ribuan windows tapi dari distribusi yang relatif terbatas, CNN-LSTM terbukti lebih stabil dalam literatur gait authentication (He et al., 2022; Choi et al., 2023). Selain itu, scope penelitian ini adalah evaluasi integrasi FL+XAI, bukan

optimasi arsitektur model. Menggunakan arsitektur yang proven memungkinkan kami mengisolasi variabel yang ingin dievaluasi.

Tips: Tambahkan: "Namun, pengujian Transformer sebagai model alternatif bisa menjadi arah penelitian lanjutan."

Pertanyaan Dosen: "Bagaimana Anda menangani masalah class imbalance antara genuine dan impostor?"

Jawaban yang Direkomendasikan:

Ada dua strategi yang diterapkan. Pertama, dalam pembangunan dataset: jumlah impostor dibatasi maksimal tiga kali jumlah genuine per partisipan, sehingga rasio tidak terlalu ekstrem. Kedua, dalam training: class weight digunakan di optimizer, di mana kelas minoritas (genuine) diberi bobot lebih tinggi secara proporsional. Metrik evaluasi yang digunakan (EER, FAR, FRR, F1-score) juga robust terhadap imbalance dibandingkan hanya menggunakan accuracy.

Tips: Jika dosen bertanya lebih dalam, sebutkan bahwa EER tidak terpengaruh oleh imbalance karena menghitung FAR dan FRR secara terpisah.

Pertanyaan Dosen: "Mengapa menggunakan simulasi FL dan bukan implementasi FL sesungguhnya di smartphone fisik?"

Jawaban yang Direkomendasikan:

Ada dua alasan utama. Pertama, alasan kelayakan: deploy FL ke 50–100 smartphone fisik memerlukan infrastruktur yang jauh melampaui scope skripsi S1. Kedua, alasan preseden ilmiah: mayoritas penelitian FL akademis menggunakan simulasi, termasuk paper FedAvg asli (McMahan et al., 2017) sendiri. Yang penting adalah bahwa simulasi merepresentasikan skenario privasi yang realistis yaitu data tidak pernah digabungkan secara langsung, hanya parameter model yang dipertukarkan. Keterbatasan ini disebutkan secara eksplisit dalam proposal.

Tips: Ini bukan kelemahan yang disembunyikan, tapi batasan yang sudah diakui dan dijustifikasi.

Pertanyaan Dosen: "Bagaimana Anda memastikan bahwa label genuine/impostor dalam dataset Anda tidak bias?"

Jawaban yang Direkomendasikan:

Data genuine untuk setiap partisipan diambil dari sesi yang sama (empat posisi smartphone). Data impostor diambil dari partisipan lain yang berbeda. Proses labeling otomatis berdasarkan participant_id dari file CSV, tidak ada labeling manual yang subjektif. Selain itu, split train/test dilakukan setelah labeling dengan stratified split untuk memastikan distribusi kelas seimbang di setiap split.

4.3 Pertanyaan tentang Federated Learning

Pertanyaan Dosen: "Apa sebenarnya yang "terjaga privasinya" dalam sistem Federated Learning Anda? Data gait masih ada di perangkat, dan Anda tetap bisa mengakses semuanya dalam simulasi."

Jawaban yang Direkomendasikan:

Ini adalah pertanyaan yang sangat tepat. Dalam implementasi FL yang sesungguhnya, privasi terjaga karena data mentah tidak pernah meninggalkan perangkat. Dalam simulasi ini, memang data secara teknis berada di satu mesin, tetapi arsitektur kode sengaja didesain sehingga setiap "client" hanya bisa mengakses datanya sendiri, dan hanya parameter model yang "dikirim" ke "server". Ini adalah simulasi fidelitas tinggi dari privasi yang akan ada dalam deployment nyata. Penelitian ini adalah proof-of-concept yang mengevaluasi apakah pendekatan ini layak secara teknis sebelum diimplementasikan secara sesungguhnya.

Tips: *Jujurlah tentang keterbatasan simulasi. Dosen akan lebih menghargai kejujuran daripada klaim berlebihan.*

Pertanyaan Dosen: *"Mengapa Anda tidak menggunakan Differential Privacy untuk memperkuat jaminan privasi?"*

Jawaban yang Direkomendasikan:

Differential Privacy (DP) menambahkan noise Gaussian ke parameter model sebelum dikirim ke server, sehingga bahkan parameter model pun tidak bisa digunakan untuk merekonstruksi data. Ini adalah teknik yang sangat kuat, tetapi memiliki tradeoff: semakin kuat privacy guarantee, semakin besar degradasi performa model. Penelitian ini sudah fokus mengukur tradeoff FL vs centralized. Menambahkan DP akan menciptakan variabel kedua yang memperumit interpretasi. Penggunaan DP bisa menjadi satu arah penelitian lanjutan yang spesifik.

Tips: *Tunjukkan bahwa Anda memahami DP dan alasan strategis mengapa tidak digunakan, bukan karena tidak tahu.*

Pertanyaan Dosen: *"Apa dampak dari distribusi data non-IID terhadap model? Bagaimana Anda mengatasinya?"*

Jawaban yang Direkomendasikan:

Dalam kondisi non-IID, model lokal setiap client bergerak ke arah yang berbeda-beda selama local training, sehingga agregasi FedAvg menghasilkan model global yang kurang optimal dibanding kondisi IID. Ini disebut "client drift". Dalam penelitian ini, dampak ini tidak diatasi secara algoritmik karena fokusnya adalah mengukur seberapa besar dampaknya melalui Skenario 3, bukan meminimalkannya. Mengatasi client drift (misalnya dengan FedProx atau SCAFFOLD) adalah arah penelitian lanjutan yang valid.

4.4 Pertanyaan tentang SHAP dan Explainability

Pertanyaan Dosen: *"Anda mengatakan SHAP diterapkan pada model global, bukan model lokal. Mengapa model global lebih relevan?"*

Jawaban yang Direkomendasikan:

Model global FedAvg adalah model yang akan digunakan pengguna dalam deployment nyata. Model lokal hanya merepresentasikan satu participant dan tidak bisa digeneralisasi. Selain itu, tujuan SHAP dalam penelitian ini adalah memvalidasi bahwa proses agregasi FL menghasilkan model yang masih menggunakan fitur yang benar secara biologis, bukan hanya model yang sudah terbukti pada satu participant. Jika model global menunjukkan feature importance yang konsisten dengan biomekanika gait, itu adalah bukti yang lebih kuat dari validitas sistem secara keseluruhan.

Pertanyaan Dosen: *"Bagaimana Anda memvalidasi bahwa SHAP values Anda bermakna dan bukan hanya noise?"*

Jawaban yang Direkomendasikan:

Ada tiga level validasi. Pertama, konsistensi internal: kami membandingkan SHAP importance dari model centralized dan federated menggunakan Spearman correlation. Jika kedua model menunjukkan pola importance yang sama ($\rho \geq 0,70$), itu mengindikasikan SHAP menangkap struktur yang nyata, bukan noise acak. Kedua, validasi domain: kami memverifikasi apakah fitur top-SHAP konsisten dengan pengetahuan biomekanika gait, khususnya acc_y untuk gerakan vertikal dan gyr_z untuk rotasi lateral, yang sudah terdokumentasi dalam literatur. Ketiga, temporal analysis: pola importance temporal harus sesuai dengan fase siklus gait yang diketahui.

Pertanyaan Dosen: *"Mengapa Anda memilih GradientExplainer dan bukan KernelExplainer atau DeepExplainer?"*

Jawaban yang Direkomendasikan:

GradientExplainer dipilih karena model yang digunakan berbasis TensorFlow/Keras, di mana GradientExplainer memanfaatkan autograd untuk menghitung SHAP values secara efisien. KernelExplainer bersifat model-agnostic tapi sangat lambat karena memerlukan banyak evaluasi model. DeepExplainer adalah opsi lain untuk deep learning tapi lebih sensitif terhadap arsitektur model. Dalam implementasi kode, ada fallback otomatis ke KernelExplainer jika GradientExplainer gagal, memastikan robustness.

4.5 Pertanyaan tentang Evaluasi dan Statistik

Pertanyaan Dosen: *"Mengapa one-sample t-test untuk H_1 ? Bukankah distribusi EER tidak selalu normal?"*

Jawaban yang Direkomendasikan:

Pertanyaan yang tepat. Secara formal, t-test mengasumsikan distribusi normal. Namun, berdasarkan Central Limit Theorem, rata-rata dari 50+ sampel mendekati distribusi normal terlepas dari distribusi aslinya. Jika ada kekhawatiran, kami bisa menggunakan Wilcoxon signed-rank test sebagai uji non-parametrik alternatif. Namun untuk penelitian ini, dengan $N \geq 50$ dan variabel kontinu, t-test adalah pilihan yang standar dan defensible.

Tips: *Jika dosen mempertanyakan ini, tunjukkan bahwa Anda tahu alternatif non-parametriknya.*

Pertanyaan Dosen: *"Bagaimana Anda menghindari data leakage dalam evaluasi?"*

Jawaban yang Direkomendasikan:

Ada tiga mekanisme pencegahan. Pertama, scaler normalisasi di-fit hanya pada training data, kemudian transform diterapkan ke validation dan test set menggunakan parameter yang sama, tidak di-fit ulang. Kedua, SHAP background data diambil dari training set saja, tidak dari test set. Ketiga, semua tuning hyperparameter dilakukan berdasarkan validation set, bukan test set. Test set hanya digunakan sekali di akhir untuk pelaporan hasil final.

Tips: *Data leakage adalah kesalahan umum yang sering ditanyakan dosen. Menguasai penjelasan ini menunjukkan kematangan metodologis.*

Pertanyaan Dosen: *"Bagaimana Anda memastikan hasil Anda tidak terlalu optimis akibat overfitting?"*

Jawaban yang Direkomendasikan:

Tiga mekanisme regulasi diterapkan. Pertama, Dropout (0,3) pada dua posisi dalam model. Kedua, Early stopping berdasarkan validation loss dengan patience 10 epoch, sehingga model berhenti sebelum overfitting. Ketiga, evaluasi final menggunakan test set yang benar-benar terpisah dan tidak pernah dilihat selama training atau tuning. Selain itu, window dari satu sesi berjalan yang sama tidak tersebar di train dan test set secara bersamaan untuk menghindari temporal leakage.

4.6 Pertanyaan tentang Kepraktisan dan Keterbatasan

Pertanyaan Dosen: *"Seberapa realistis sistem ini untuk diimplementasikan di dunia nyata?"*

Jawaban yang Direkomendasikan:

Penelitian ini secara eksplisit adalah proof-of-concept dengan offline evaluation, bukan sistem siap produksi. Untuk deployment nyata, ada beberapa tantangan yang harus diselesaikan: pertama, latensi autentikasi di smartphone nyata harus dioptimalkan; kedua, FL harus diimplementasikan dengan jaringan nyata dan mengelola client yang dropout; ketiga, regulasi privasi data biometrik di berbagai negara harus dipatuhi. Yang kami buktikan adalah bahwa secara teknis, integrasi ketiga komponen ini menghasilkan performa yang acceptable dan layak untuk dikejar lebih jauh.

Tips: *Kejujuran tentang gap antara penelitian dan produksi selalu dihargai dosen.*

Pertanyaan Dosen: *"Apa yang terjadi jika seseorang berjalan dengan gaya yang berbeda karena sedang terburu-buru atau sakit?"*

Jawaban yang Direkomendasikan:

Ini adalah keterbatasan yang valid dari biometrik berbasis gait. Variabilitas gait intra-personal memang ada dan bisa meningkatkan FRR. Ada beberapa mitigasi yang dilakukan dalam penelitian ini: pengumpulan data dari empat posisi smartphone yang berbeda meningkatkan robustness terhadap variasi posisi perangkat. Skenario 4 (multi-position robustness) secara khusus mengevaluasi generalisasi ini. Variabilitas akibat kondisi fisik pengguna adalah keterbatasan yang disebutkan secara eksplisit dan bisa menjadi topik penelitian lanjutan.

Pertanyaan Dosen: *"Apakah 50–100 partisipan cukup untuk mengklaim generalisabilitas?"*

Jawaban yang Direkomendasikan:

Untuk sebuah proof-of-concept dan evaluasi integrasi, 50–100 partisipan sudah jauh lebih banyak dari mayoritas studi serupa (Choi: 10, He: 21). Namun, kami tidak mengklaim bahwa temuan ini langsung generalizable ke seluruh populasi dunia. Penelitian ini memberikan bukti awal (preliminary evidence) bahwa pendekatan ini layak. Generalisabilitas yang lebih luas memerlukan dataset yang lebih besar dan lebih beragam (usia, budaya, kondisi fisik), yang bisa menjadi arah penelitian lanjutan.

4.7 Pertanyaan Lintas-Topik yang Harus dikuasai

Pertanyaan Dosen: *"Coba jelaskan secara singkat bagaimana cara kerja FedAvg dalam satu kalimat."*

Jawaban yang Direkomendasikan:

Setiap perangkat melatih model lokal menggunakan datanya sendiri, lalu server menghitung rata-rata tertimbang dari semua model lokal tersebut untuk menghasilkan model global yang lebih baik, dan proses ini diulang berkali-kali.

Tips: *Latih jawaban singkat ini. Dosen sering meminta penjelasan singkat untuk menguji pemahaman dasar.*

Pertanyaan Dosen: *"Apa perbedaan antara FAR dan FRR, dan mengapa keduanya penting dalam konteks autentikasi?"*

Jawaban yang Direkomendasikan:

FAR (False Acceptance Rate) adalah persentase orang yang bukan kita (impostor) tapi berhasil masuk ke sistem kita. Ini adalah risiko keamanan. FRR (False Rejection Rate) adalah persentase kita sendiri yang ditolak oleh sistem. Ini adalah risiko kemudahan penggunaan. Keduanya trade-off: jika threshold dinaikkan, FAR turun tapi FRR naik, dan sebaliknya. EER adalah titik keseimbangan optimal di mana FAR = FRR.

Pertanyaan Dosen: *"Jika hasilnya buruk, apakah penelitian Anda masih berguna?"*

Jawaban yang Direkomendasikan:

Tentu saja. Dalam penelitian ilmiah, hasil negatif (null result) sama berharganya dengan hasil positif. Jika EER tidak mencapai target, temuan tersebut memberikan informasi penting tentang kondisi batas kemampuan sistem gait authentication berbasis FL. Selain itu, analisis SHAP dan evaluasi trade-off FL vs centralized tetap menghasilkan kontribusi yang valid terlepas dari nilai EER absolut. Yang penting adalah metodologi yang rigorous dan pelaporan hasil yang jujur.

Tips: *Dosen sering menanyakan ini untuk menguji kematangan peneliti. Jangan panik jika hasilnya tidak mencapai target.*

Semangat bimbingannya, Dave! You got this.