

PROPOSAL SKRIPSI NON KELAS

**AUTENTIKASI AMAN BERBASIS POLA BERJALAN
MENGUNAKAN EXPLAINABLE FEDERATED LEARNING**

***SECURE GAIT-BASED AUTHENTICATION USING EXPLAINABLE
FEDERATED LEARNING***

Topik: Artificial Intelligence

2602077736 Dave Tjong
Computer Science - Alam Sutera
081373417303

BINUS University
2026

Diperiksa oleh
D3690 - Derwin Suhartono

DAFTAR ISI

BAB 1. PENDAHULUAN

- 1.1 Latar Belakang
- 1.2 Rumusan Masalah
- 1.3 Hipotesis Penelitian
- 1.4 Ruang Lingkup
- 1.5 Tujuan dan Manfaat
- 1.6 Gambaran Umum Metodologi

BAB 2. TINJAUAN PUSTAKA

- 2.1 Teori yang Berkaitan
- 2.2 State of the Art

BAB 3. METODE PELAKSANAAN

- 3.1 Kerangka Berpikir
- 3.2 Metode Penelitian

DAFTAR PUSTAKA

BAB 1. PENDAHULUAN

1.1 Latar Belakang

Metode autentikasi konvensional seperti password, PIN, dan biometrik statis (wajah, sidik jari, suara) semakin rentan terhadap serangan digital modern. Teknologi generative AI mampu memalsukan wajah dan suara dengan tingkat keberhasilan yang tinggi, sehingga keamanan sistem autentikasi berbasis biometrik statis perlu dipertanyakan (Khaund et al., 2025; Nguyen et al., 2022). Kerentanan ini mendorong eksplorasi metode autentikasi alternatif yang lebih sulit dipalsukan.

Autentikasi berbasis gait menawarkan pendekatan yang menjanjikan untuk mengatasi kelemahan biometrik statis. Penelitian dalam bidang biomekanika menunjukkan bahwa gait memiliki tiga keunggulan utama sebagai biometrik: bersifat kontinu sehingga memungkinkan autentikasi pasif tanpa interaksi aktif pengguna, sulit dipalsukan karena mencerminkan karakteristik muskuloskeletal yang unik, dan dapat diimplementasikan menggunakan sensor accelerometer dan gyroscope yang sudah tersedia di hampir semua smartphone (Muaaz dan Mayrhofer, 2017; Cola et al., 2016). Dalam konteks penelitian ini, istilah "autentikasi berbasis gait" merujuk pada proses verifikasi identitas pengguna secara eksplisit berdasarkan pola berjalan, yang dibedakan dari pendekatan implisit yang hanya memantau gait sebagai sinyal pelengkap tanpa menjadikannya penentu utama keputusan autentikasi.

Meskipun demikian, penggunaan data gait untuk autentikasi menimbulkan dua tantangan kritis. Pertama, masalah privasi data. Data sensor gait mengandung informasi sensitif tentang identitas dan aktivitas fisik pengguna. Pengiriman data mentah ke server pusat menimbulkan risiko kebocoran privasi yang signifikan. Kedua, masalah interpretabilitas model. Sistem autentikasi berbasis deep learning yang bersifat black-box sulit divalidasi, sehingga rentan terhadap risiko model bergantung pada artefak data atau noise, bukan pada karakteristik biometrik yang sesungguhnya.

Federated Learning (FL) menawarkan solusi untuk masalah privasi dengan melatih model secara terdistribusi di perangkat pengguna tanpa mengirimkan data mentah ke server pusat (McMahan et al., 2017). Dalam arsitektur FL, setiap perangkat hanya mengirimkan parameter model yang telah diperbarui secara lokal, sehingga data biometrik tetap tersimpan di perangkat masing-masing pengguna.

Sementara itu, Explainable AI (XAI) memberikan transparansi dengan mengidentifikasi fitur gait mana yang berkontribusi terhadap keputusan autentikasi (Arrieta et al., 2020). Metode seperti SHAP (SHapley Additive exPlanations) memungkinkan validasi bahwa model menggunakan karakteristik biologis yang relevan, bukan noise atau artefak sensor (Lundberg dan Lee, 2017).

Penelitian ini mengintegrasikan gait-based authentication, Federated Learning, dan Explainable AI dalam satu sistem komprehensif. Integrasi ini bertujuan menghasilkan sistem autentikasi yang aman, privacy-preserving, dan dapat dipercaya melalui interpretabilitas model yang terverifikasi.

1.2 Rumusan Masalah

Penelitian ini menjawab tiga pertanyaan penelitian utama:

RQ1 (Efektivitas): Seberapa efektif gait sebagai metode autentikasi berdasarkan metrik accuracy, precision, recall, F1-score, False Acceptance Rate (FAR), False Rejection Rate (FRR), dan Equal Error Rate (EER)?

RQ2 (Privacy-Performance Trade-off): Bagaimana trade-off antara privasi dan performa ketika menggunakan Federated Learning dibandingkan pelatihan terpusat, terutama dalam kondisi data non-IID (non-identically and independently distributed)?

RQ3 (Explainability): Bagaimana SHAP dapat mengidentifikasi fitur gait yang paling berkontribusi terhadap keputusan autentikasi pada model federated global, serta memastikan model tidak bergantung pada artefak atau noise?

1.3 Hipotesis Penelitian

Berdasarkan rumusan masalah di atas, penelitian ini mengajukan tiga hipotesis yang akan diuji secara statistik:

H1 (Efektivitas): Sistem autentikasi gait yang dikembangkan mampu mencapai Equal Error Rate (EER) di bawah 5%, yang secara statistik lebih baik dibandingkan baseline EER sebesar 5%. Hipotesis nol yang diuji adalah H_0 : EER lebih besar dari atau sama dengan 5%, sedangkan hipotesis alternatif adalah H_1 : EER lebih kecil dari 5%.

H2 (FL Trade-off): Degradasi performa model Federated Learning dibandingkan pelatihan terpusat tidak melebihi 5 poin persentase dalam hal akurasi. Hipotesis nol yang

diuji adalah H_0 : penurunan akurasi FL lebih besar dari 5%, sedangkan hipotesis alternatif adalah H_1 : penurunan akurasi FL tidak melebihi 5%.

H3 (Explainability): Fitur-fitur gait yang diidentifikasi oleh SHAP pada model global (FedAvg) konsisten dengan pengetahuan domain biomekanika gait, yaitu sumbu accelerometer-y sebagai representasi gerakan vertikal dan sumbu gyroscope-z sebagai representasi gerakan rotasional akan muncul sebagai fitur dengan kontribusi tertinggi.

1.4 Ruang Lingkup

Ruang lingkup penelitian ini adalah sebagai berikut:

- Penelitian ini berfokus pada pengembangan sistem autentikasi berbasis gait menggunakan sensor smartphone (accelerometer dan gyroscope 3-axis).
- Penelitian menggunakan dataset yang dikumpulkan sendiri dari 50 hingga 100 partisipan dewasa sehat dengan empat posisi smartphone berbeda, yaitu pocket kiri, pocket kanan, tangan kiri, dan tangan kanan.
- Penelitian menerapkan arsitektur CNN-LSTM untuk ekstraksi fitur spasial-temporal dari data gait.
- Penelitian mengimplementasikan Federated Learning menggunakan algoritma FedAvg untuk privacy-preserving training dalam skenario simulasi pada satu mesin, bukan deployment terdistribusi secara fisik.
- Penelitian menggunakan SHAP untuk analisis explainability pada model agregasi global hasil FedAvg.
- Evaluasi dilakukan menggunakan authentication metrics (accuracy, precision, recall, F1-score, FAR, FRR, EER) dan FL performance metrics (convergence rate, communication cost).
- Pengumpulan data dilakukan di indoor flat corridor dengan kecepatan berjalan natural dan durasi 90 hingga 100 detik per partisipan.

Batasan yang secara eksplisit tidak termasuk dalam penelitian ini adalah:

- Penelitian ini tidak menerapkan teknik privacy enhancement lanjutan seperti differential privacy atau homomorphic encryption yang dapat memperkuat jaminan privasi secara formal.

- Penelitian ini tidak mencakup analisis robustness terhadap adversarial attacks seperti gradient-based attacks atau model poisoning.
- Penelitian ini tidak mencakup variasi lingkungan seperti outdoor walking, tangga, atau variasi kecepatan ekstrem.
- Penelitian ini merupakan proof-of-concept dengan offline evaluation, bukan live deployment system pada smartphone.

1.5 Tujuan dan Manfaat

Tujuan dari penelitian ini adalah:

1. Mengevaluasi efektivitas gait sebagai biometrik untuk autentikasi dengan target performa EER di bawah 5% dan accuracy di atas 90%, berdasarkan benchmark dari studi-studi terkait yang menggunakan dataset dengan skala serupa.
2. Membandingkan performa Federated Learning dengan pelatihan terpusat untuk mengukur privacy-performance trade-off.
3. Menganalisis dampak distribusi data non-IID terhadap konvergensi dan akurasi model federated.
4. Mengidentifikasi fitur gait yang paling berkontribusi terhadap keputusan autentikasi menggunakan SHAP pada model agregasi global.
5. Memvalidasi bahwa model menggunakan karakteristik biologis yang relevan, bukan artefak data atau noise sensor.

Manfaat dari penelitian ini adalah:

6. Menyediakan evaluasi komprehensif integrasi Federated Learning dan Explainable AI pada sistem gait-based authentication sebagai kontribusi metodologis.
7. Menjadi referensi untuk penelitian autentikasi biometrik perilaku dengan fokus privacy preservation dan interpretabilitas model.
8. Menyediakan baseline metrik evaluasi (FAR, FRR, EER, convergence rate) untuk penelitian serupa di masa depan.
9. Menunjukkan potensi gait sebagai alternatif autentikasi yang lebih tahan terhadap serangan pemalsuan berbasis AI.

10. Membuktikan kelayakan teknis Federated Learning untuk sistem autentikasi berbasis sensor pada perangkat mobile dalam skenario simulasi.
11. Meningkatkan kepercayaan pengguna terhadap AI-based authentication melalui transparansi model yang dapat dijelaskan.

1.6 Gambaran Umum Metodologi

Penelitian ini menggunakan pendekatan eksperimental kuantitatif untuk mengembangkan dan mengevaluasi sistem autentikasi gait yang mengintegrasikan Federated Learning dan Explainable AI. Secara garis besar, penelitian dilaksanakan dalam tiga fase utama, yaitu fase pengembangan sistem (development), fase eksperimen dan evaluasi, serta fase analisis dan dokumentasi.

Pada fase pengembangan, peneliti membangun aplikasi Android untuk pengumpulan data sensor, mengimplementasikan arsitektur CNN-LSTM untuk ekstraksi fitur gait, menyiapkan framework Federated Learning berbasis Flower, dan mengintegrasikan SHAP untuk analisis explainability. Pada fase evaluasi, data dikumpulkan dari partisipan dan dijalankan lima skenario eksperimen untuk menjawab research questions yang telah ditetapkan. Pada fase analisis, dilakukan pengujian statistik, interpretability validation, dan benchmarking terhadap literatur terkait. Detail metodologi dipaparkan secara komprehensif pada Bab 3.

BAB 2. TINJAUAN PUSTAKA

2.1 Teori yang Berkaitan

Gait-Based Authentication

Gait adalah pola berjalan yang unik untuk setiap individu, dipengaruhi oleh kombinasi kompleks struktur tulang, massa otot, distribusi berat badan, dan kebiasaan motorik (Kharb et al., 2011). Penelitian di bidang biometrik menunjukkan bahwa gait memiliki stabilitas yang cukup tinggi untuk digunakan sebagai fitur identifikasi, karena pola berjalan seseorang relatif konsisten dalam berbagai kondisi.

Dalam konteks autentikasi berbasis sensor, data gait diperoleh melalui accelerometer dan gyroscope yang mengukur percepatan linear dan kecepatan angular pada tiga sumbu (x, y, z). Sensor inersial ini mampu mengkodekan karakteristik gait seperti siklus langkah, amplitudo gerakan vertikal, dan pola rotasi tubuh ke dalam sinyal time-series yang dapat diolah oleh model machine learning (Muaaz dan Mayrhofer, 2017). Pendekatan berbasis sensor ini lebih praktis dibandingkan pendekatan berbasis video karena menggunakan perangkat yang sudah dimiliki pengguna.

Verifikasi gait yang dikembangkan dalam penelitian ini bersifat eksplisit, artinya sistem secara aktif menggunakan pola berjalan sebagai penentu utama keputusan autentikasi, berbeda dari sistem implisit yang hanya menggunakan gait sebagai sinyal pelengkap atau monitoring pasif terus-menerus. Pendekatan eksplisit memiliki kelebihan berupa kontrol yang lebih baik atas momen autentikasi, namun membutuhkan periode pengambilan data yang cukup untuk mengekstraksi pola yang representatif.

Federated Learning

Federated Learning adalah paradigma machine learning terdistribusi yang memungkinkan pelatihan model secara kolaboratif tanpa sentralisasi data (McMahan et al., 2017). Dalam FL, setiap client (perangkat pengguna) melakukan proses pelatihan model secara lokal menggunakan data pribadi masing-masing, kemudian hanya mengirimkan parameter model yang diperbarui (gradient atau bobot) ke server pusat untuk agregasi. Data mentah tidak pernah meninggalkan perangkat pengguna.

FedAvg (Federated Averaging) adalah algoritma agregasi paling umum digunakan dalam FL (McMahan et al., 2017). Algoritma ini bekerja dengan weighted average terhadap parameter model lokal dari multiple clients, di mana bobotnya proporsional terhadap

jumlah data lokal masing-masing client. Parameter model global yang dihasilkan kemudian didistribusikan kembali ke semua client sebagai model inisialisasi untuk putaran berikutnya.

Tantangan utama FL meliputi: (1) distribusi data non-IID, di mana data tidak terdistribusi secara identik dan independen antar client, yang dapat memperlambat konvergensi dan menurunkan akurasi model global; (2) biaya komunikasi yang tinggi untuk transfer parameter model, terutama pada arsitektur deep learning dengan jumlah parameter besar; dan (3) heterogenitas sistem, di mana perangkat client memiliki kapabilitas komputasi yang berbeda-beda (Li et al., 2020).

Explainable AI untuk Autentikasi

Explainable AI (XAI) bertujuan membuat proses pengambilan keputusan model AI lebih transparan dan dapat diinterpretasikan (Arrieta et al., 2020). Dalam sistem autentikasi, XAI penting untuk validasi bahwa model menggunakan fitur yang secara biologis dan fisika relevan, bukan bergantung pada korelasi palsu atau artefak data yang dapat mengurangi keandalan sistem di dunia nyata.

SHAP (SHapley Additive exPlanations) adalah metode model-agnostic XAI yang menggunakan konsep Shapley value dari cooperative game theory untuk menghitung kontribusi setiap fitur terhadap prediksi model (Lundberg dan Lee, 2017). SHAP memiliki fondasi matematika yang kuat dan menghasilkan atribusi fitur yang konsisten dan locally accurate, sehingga lebih dapat diandalkan dibandingkan metode explainability yang lebih sederhana seperti gradient-based saliency maps.

Dalam konteks penelitian ini, SHAP diaplikasikan pada model agregasi global yang dihasilkan oleh FedAvg, bukan pada model lokal masing-masing client. Pendekatan ini dipilih karena model global merepresentasikan pengetahuan kolektif dari semua partisipan dan menjadi model yang digunakan dalam deployment, sehingga interpretabilitas model global lebih relevan secara praktis. Dengan menganalisis kontribusi fitur pada model global, penelitian ini dapat memvalidasi apakah sumbu sensor tertentu seperti accelerometer-y untuk gerakan vertikal dan gyroscope-z untuk gerakan rotasional memang menjadi penentu utama keputusan autentikasi sesuai ekspektasi biomekanika gait.

2.2 State of the Art

Smartphone Authentication System Using Personal Gaits and Deep Learning (Choi et al., 2023)

Choi et al. (2023) mengembangkan sistem autentikasi smartphone berbasis gait menggunakan Convolutional Neural Network (CNN) untuk mengatasi keterbatasan dataset publik yang dikumpulkan dari sensor yang dipasang tetap. Penelitian ini mengumpulkan dataset sendiri menggunakan smartphone yang dibawa oleh pengguna dalam kondisi natural, mencakup variasi posisi perangkat dan kecepatan berjalan.

Hasil evaluasi menunjukkan performa yang solid dengan average accuracy 91,76%, precision 91,02%, recall 92,83%, dan F1-score 91,81%. Authentication time mencapai 1,8 detik, jauh lebih cepat dibandingkan metode biometrik aktif. Nilai-nilai ini menjadi salah satu referensi dalam penetapan target performa penelitian ini.

Keterbatasan penelitian ini mencakup sample size yang hanya 10 partisipan, sehingga validasi statistik yang dihasilkan belum cukup robust. Model hanya menggunakan CNN tanpa komponen recurrent untuk menangkap dependensi temporal jangka panjang. Selain itu, tidak ada komponen Federated Learning maupun XAI, sehingga aspek privasi dan interpretabilitas tidak dapat dievaluasi.

A Comprehensive Survey on Federated Learning and Explainable AI for Gait-Based Activity Recognition (Swaroop Rani, 2025)

Swaroop Rani (2025) melakukan comprehensive survey terhadap integrasi Federated Learning dan Explainable AI dalam gait-based activity recognition, menganalisis papers dari 2019 hingga 2024 yang dipublikasikan di berbagai jurnal internasional bereputasi.

Temuan utama menunjukkan bahwa Hierarchical FL combined dengan Hybrid XAI mencapai akurasi tertinggi (93,1%) dan skor privasi terkuat (0,91), meskipun dengan biaya komputasi yang lebih tinggi. FedAvg dengan XAI standar memberikan keseimbangan performa dan efisiensi yang lebih baik sebagai baseline yang dapat direplikasi secara praktis.

Keterbatasan survey ini adalah sifatnya yang teoretis tanpa eksperimen empiris baru, dan dataset yang dianalisis umumnya dirancang untuk activity recognition, bukan autentikasi. Banyak dataset gait yang tersedia juga tidak memiliki partisi federated yang realistis, sehingga evaluasi FL dilakukan secara simulasi. Penelitian ini menjadi justifikasi bahwa gap penelitian masih ada pada domain autentikasi (bukan hanya activity recognition) dengan FL dan XAI.

Gait2Vec: Continuous Authentication of Smartphone Users Based on Gait Behavior (He et al., 2022)

He et al. (2022) mengembangkan feature extractor berbasis transfer learning bernama Gait2Vec untuk gait authentication yang robust terhadap variasi sensor position, walking speed, dan environmental scenarios. Pendekatan ini menggunakan pre-training untuk menghasilkan representasi gait yang dapat digeneralisasi.

Model architecture menggunakan 3 Conv1D layers dengan batch normalization, max pooling, dan dropout sebagai Gait2Vec feature extractor. Hasil evaluasi menunjukkan bahwa 6-axis data (accelerometer dan gyroscope) memberikan performa yang secara konsisten lebih baik dibandingkan 3-axis saja, mendukung keputusan penelitian ini untuk menggunakan kedua sensor.

Keterbatasan penelitian mencakup sample size yang moderat (21 subjek), tidak menggunakan Federated Learning atau teknik privacy-preserving, dan tidak ada analisis explainability menggunakan SHAP atau metode XAI lainnya.

Federated Learning for Gait-Based User Authentication on Smartphones (Zhang et al., 2022)

Zhang et al. (2022) mengimplementasikan Federated Learning secara langsung untuk sistem autentikasi gait pada smartphone, menjadikannya salah satu studi yang paling relevan dengan penelitian ini. Penelitian ini mengevaluasi FedAvg dalam skenario distribusi data non-IID yang disimulasikan menggunakan Dirichlet distribution.

Hasil menunjukkan bahwa model federated mampu mendekati performa model terpusat dengan penurunan akurasi rata-rata sekitar 3 hingga 4 poin persentase, mendukung hipotesis H2 dalam penelitian ini. Penelitian juga mencatat bahwa semakin kecil nilai parameter konsentrasi Dirichlet, semakin besar penurunan performa yang terjadi akibat heterogenitas data.

Keterbatasan utama penelitian ini adalah tidak adanya komponen explainability, sehingga tidak dapat diverifikasi apakah model federated yang dihasilkan menggunakan fitur yang secara biomekanika bermakna.

Smartphone-Based Gait Recognition: From Authentication to Imitation (Muaaz dan Mayrhofer, 2017)

Muaaz dan Mayrhofer (2017) mengevaluasi kerentanan sistem autentikasi gait berbasis smartphone terhadap serangan imitasi, di mana penyerang mencoba meniru gait target

secara sengaja. Studi ini memberikan perspektif penting tentang batas keamanan gait sebagai biometrik.

Temuan utama menunjukkan bahwa meskipun gait sulit diimitasi secara alami, serangan imitasi yang terlatih dapat meningkatkan False Acceptance Rate secara signifikan. Penelitian ini menjadi dasar justifikasi mengapa evaluasi FAR dan EER secara ketat diperlukan dalam penelitian ini, serta mengapa autentikasi gait perlu dikombinasikan dengan lapisan keamanan tambahan untuk deployment produksi.

Explainable Deep Learning for Gait Recognition Using Attention Mechanisms and SHAP Analysis (Li et al., 2023)

Li et al. (2023) menggabungkan attention mechanisms dengan SHAP analysis untuk meningkatkan interpretabilitas model gait recognition. Penelitian ini menunjukkan bahwa SHAP secara konsisten mengidentifikasi sumbu accelerometer-y dan gyroscope-z sebagai fitur terpenting, konsisten dengan ekspektasi biomekanika gait.

Studi ini memberikan validasi empiris untuk hipotesis H3 dalam penelitian ini dan sekaligus menjadi benchmark untuk interpretability validation. Keterbatasan penelitian ini adalah tidak menggunakan Federated Learning, sehingga tidak diketahui apakah pola SHAP yang sama akan terjadi pada model yang dilatih secara federated.

BAB 3. METODE PELAKSANAAN

3.1 Kerangka Berpikir

Kerangka berpikir penelitian ini menggambarkan tahapan sistematis untuk mengembangkan dan mengevaluasi sistem autentikasi gait berbasis Federated Learning dan Explainable AI. Penelitian dimulai dari identifikasi masalah privasi dan interpretabilitas pada sistem autentikasi biometrik, dilanjutkan dengan pengumpulan data, pengembangan model, eksperimen dalam lima skenario terstruktur, hingga analisis hasil dan penarikan kesimpulan.

[Gambar 3.1 Flowchart Kerangka Berpikir Penelitian]

3.2 Metode Penelitian

Metode penelitian ini menguraikan secara detail setiap tahapan yang digambarkan dalam kerangka berpikir di atas.

3.2.1 Etika Penelitian dan Informed Consent

Penelitian ini melibatkan pengumpulan data biometrik dari partisipan manusia, sehingga aspek etika penelitian menjadi prioritas utama. Sebelum pengumpulan data dimulai, penelitian akan memperoleh persetujuan dari komite etika penelitian universitas. Seluruh partisipan akan diberikan penjelasan lengkap mengenai tujuan penelitian, jenis data yang dikumpulkan, cara penggunaan data, dan hak mereka untuk mengundurkan diri kapan saja tanpa konsekuensi negatif. Persetujuan tertulis (informed consent) akan diperoleh dari setiap partisipan sebelum sesi pengumpulan data dimulai.

Data yang dikumpulkan akan disimpan secara anonim dengan menggunakan kode partisipan, bukan nama asli. Akses terhadap data mentah dibatasi hanya untuk tim peneliti. Data tidak akan dibagikan kepada pihak ketiga dan akan dihapus setelah penelitian selesai dan publikasi diterbitkan. Partisipan yang berusia di bawah 18 tahun tidak akan diikutsertakan dalam penelitian ini.

3.2.2 Pengumpulan Data Gait

Pengembangan Aplikasi Android

Aplikasi mobile dikembangkan menggunakan Android Studio dengan fitur real-time sensor data capture dari accelerometer dan gyroscope pada sampling rate 50 Hz. Pemilihan sampling rate 50 Hz didasarkan pada pertimbangan bahwa komponen

frekuensi utama gait berada di bawah 20 Hz, sehingga 50 Hz memenuhi syarat Nyquist dengan margin yang cukup. Aplikasi menyimpan data dalam format CSV dengan timestamp untuk sinkronisasi antar sesi.

Rekrutmen Partisipan

Target penelitian adalah 50 hingga 100 partisipan dewasa sehat berusia 18 hingga 60 tahun yang direkrut melalui campus announcements, media sosial, dan snowball sampling. Sample size ditentukan berdasarkan power analysis dengan asumsi effect size medium (Cohen's $d = 0,5$), power 0,80, dan significance level $\alpha = 0,05$, yang menghasilkan kebutuhan minimum 50 partisipan untuk pengujian hipotesis one-sample t-test. Penambahan hingga 100 partisipan memberikan buffer untuk mengantisipasi drop-out dan memperkuat generalisasi hasil.

Rencana rekrutmen mencakup periode empat minggu dengan dua sesi per hari, masing-masing sesi dapat menangani lima partisipan. Dengan asumsi tingkat partisipasi 80%, target rekrutmen awal adalah 75 partisipan untuk memastikan minimal 60 data yang dapat digunakan.

Protokol Pengumpulan Data

Data gait dikumpulkan di indoor flat corridor sepanjang 20 meter. Setiap partisipan melakukan walking trials dengan smartphone ditempatkan di empat posisi berbeda: pocket kanan, pocket kiri, tangan kanan, dan tangan kiri. Setiap sesi berjalan berlangsung selama 90 hingga 100 detik dengan kecepatan natural. Partisipan diminta berjalan dalam tiga putaran bolak-balik untuk setiap posisi smartphone, dengan jeda istirahat dua menit antar posisi untuk menghindari kelelahan. Total waktu per partisipan diperkirakan 30 hingga 40 menit termasuk persiapan dan pengisian informed consent.

Preprocessing Data

Data mentah melalui empat tahap preprocessing. Pertama, linear interpolation untuk mengompensasi missing data points akibat error sampling dengan toleransi 0,5 hingga 1 ms. Kedua, Butterworth low-pass filter dengan cutoff frequency 20 Hz untuk menghilangkan high-frequency noise yang bukan berasal dari gerakan gait. Ketiga, segmentasi sinyal menggunakan sliding window dengan ukuran 128 samples (setara 2,56 detik pada 50 Hz) dan overlap 50%. Ukuran window 128 dipilih berdasarkan literatur (He et al., 2022; Choi et al., 2023) yang menunjukkan window tersebut cukup untuk menangkap satu hingga dua siklus gait lengkap. Keempat, normalisasi menggunakan z-

score normalization per sensor axis untuk mengurangi bias akibat perbedaan orientasi perangkat.

Setiap window menghasilkan input tensor berukuran 128×6 (128 timesteps, 6 channel: 3 axis accelerometer dan 3 axis gyroscope) yang menjadi input untuk model CNN-LSTM.

3.2.3 Pengembangan Model

Desain Arsitektur CNN-LSTM

Model hybrid CNN-LSTM dirancang untuk mengekstraksi fitur spasial dan temporal dari data gait. CNN layers terdiri dari dua convolutional blocks, masing-masing mengandung Conv1D layer (filters 64 dan 128, kernel size 3) diikuti oleh Batch Normalization, ReLU activation, dan MaxPooling1D. Komponen LSTM terdiri dari dua LSTM layers (128 units dan 64 units) untuk menangkap dependensi temporal jangka panjang dalam sinyal gait. Classification head menggunakan Dense layer dengan Sigmoid activation untuk binary verification (genuine vs. impostor). Dropout dengan rate 0,3 diterapkan sebelum layer LSTM untuk regularisasi.

Implementasi Federated Learning

Federated Learning diimplementasikan menggunakan Flower framework versi 1.5 ke atas dengan algoritma FedAvg. Dalam simulasi ini, setiap partisipan dimodelkan sebagai satu client yang terpisah, sehingga jumlah client sama dengan jumlah partisipan. Konfigurasi FL meliputi jumlah total clients sebesar 50 hingga 100 (1 user = 1 client), clients per round K divariasikan antara 10, 25, dan 50 untuk analisis sensitivitas, serta local epochs E ditetapkan sebesar 5.

Agregasi global menggunakan formula FedAvg sebagai berikut: parameter model global adalah jumlah dari (bobot lokal client k dikalikan dengan parameter model lokal client k) untuk semua k dari 1 hingga K , di mana bobot lokal client k adalah rasio jumlah training samples lokal client k terhadap total training samples seluruh client. Privacy dijaga dengan zero raw data transfer karena hanya parameter model yang dikirimkan, sesuai dengan prinsip dasar Federated Learning.

Non-IID Data Simulation

Untuk mensimulasikan skenario federated yang realistis, data dipartisi dengan controlled heterogeneity menggunakan Dirichlet distribution. Concentration parameter α

divariasikan: alpha tidak terhingga untuk skenario IID sebagai baseline, alpha 1,0 untuk heterogenitas ringan, alpha 0,5 untuk heterogenitas sedang, dan alpha 0,1 untuk heterogenitas tinggi. Semakin kecil nilai alpha, semakin tidak merata distribusi data antar client, yang memodelkan kondisi nyata di mana pengguna yang berbeda memiliki pola gait yang sangat berbeda.

Integrasi SHAP untuk Explainability

SHAP diintegrasikan untuk post-hoc analysis setelah model training selesai. Analisis SHAP dilakukan secara eksklusif pada model agregasi global (model global hasil FedAvg), bukan pada model lokal masing-masing client. Pemilihan ini didasarkan pada pertimbangan bahwa model global adalah model yang akan digunakan dalam deployment dan merepresentasikan pengetahuan kolektif dari semua partisipan, sehingga interpretabilitasnya lebih relevan secara praktis.

Workflow SHAP meliputi: (1) seleksi 100 instance representatif dari training set sebagai background data untuk estimasi baseline; (2) komputasi SHAP values untuk setiap feature (sensor axis dan timestep) pada 200 test instances; (3) visualisasi feature importance melalui SHAP summary plot dan dependence plot; dan (4) temporal importance analysis untuk mengidentifikasi fase gait cycle mana yang paling informatif.

3.2.4 Eksperimen dan Evaluasi

Penelitian melakukan lima skenario eksperimen untuk menjawab research questions.

Skenario 1: Baseline Evaluation

Centralized training dengan semua data untuk baseline performance. Model dilatih menggunakan gabungan dataset dari semua partisipan tanpa federated partitioning. Evaluasi menggunakan accuracy, precision, recall, F1-score, FAR, FRR, dan EER. Hasil skenario ini menjadi acuan atas (upper bound) performa yang diharapkan dari model federated.

Skenario 2: Perbandingan FL dengan Centralized

Perbandingan empat kondisi untuk mengevaluasi privacy-performance trade-off: (A) Centralized baseline, (B) Federated dengan $K=10$ dan $E=5$, (C) Federated dengan $K=25$ dan $E=5$, dan (D) Federated dengan $K=50$ dan $E=5$. Semua skenario menggunakan distribusi IID untuk mengisolasi dampak federated training dari dampak data heterogeneity.

Skenario 3: Analisis Dampak Non-IID

Analisis dampak data heterogeneity dengan varying Dirichlet concentration parameter alpha (tidak terhingga, 1,0, 0,5, 0,1). Untuk setiap nilai alpha, FL training dilakukan dengan konfigurasi tetap ($K=10$, $E=5$) dan convergence dipantau hingga 100 communication rounds atau hingga kriteria berhenti terpenuhi.

Skenario 4: Multi-Position Robustness

Validasi generalization across smartphone positions dengan train-test split berdasarkan posisi. Training set menggunakan data dari tiga posisi (pocket kiri, pocket kanan, tangan kiri), test set menggunakan data dari posisi tangan kanan yang tidak terlihat saat training. Skenario ini mengevaluasi kemampuan model untuk berfungsi meskipun posisi smartphone pengguna bervariasi.

Skenario 5: SHAP Feature Analysis

SHAP analysis pada trained model (centralized dan federated global) untuk identifikasi important gait features. Output berupa feature importance rankings (top-10 sensor axes dan timesteps), temporal importance analysis, dan validasi konsistensi antara model centralized dan federated.

3.2.5 Analisis Hasil

Statistical Testing

Hypothesis testing dilakukan untuk memvalidasi research questions. Pengujian H1 menggunakan one-sample t-test dengan H_0 : EER lebih besar dari atau sama dengan 5% vs H_1 : EER lebih kecil dari 5%, pada significance level $\alpha = 0,05$. Pengujian H2 menggunakan paired t-test membandingkan akurasi FL vs centralized, dengan H_0 : perbedaan lebih besar dari 5% vs H_1 : perbedaan tidak melebihi 5%. Pengujian H3 dilakukan melalui Spearman rank correlation antara SHAP feature importance rankings dari model centralized dan federated, dengan ekspektasi korelasi positif dan signifikan (ρ lebih besar dari 0,7).

Performance Comparison

Comparative analysis dilakukan untuk benchmarking terhadap baseline dan state-of-the-art. Tabel perbandingan dibuat untuk merangkum accuracy, EER, convergence rounds, communication cost, dan interpretability score (konsistensi SHAP dengan biomekanika gait) antar skenario eksperimen dan antar studi terkait.

Interpretability Validation

SHAP feature importance results divalidasi dengan domain knowledge dari gait biomechanics literature. Fitur yang diharapkan muncul sebagai yang paling penting berdasarkan literatur adalah accelerometer-y sebagai representasi gerakan vertikal akibat ground reaction force (Cola et al., 2016), gyroscope-z sebagai representasi gerakan rotasional selama stride (Li et al., 2023), dan accelerometer-magnitude sebagai representasi intensitas gerakan keseluruhan. Apabila fitur-fitur tersebut muncul dalam top-5 SHAP feature importance, maka H3 dianggap terkonfirmasi.

DAFTAR PUSTAKA

- Arrieta, A. B., Diaz-Rodriguez, N., Del Ser, J., Bennetot, A., Tabik, S., Barbado, A., Garcia, S., Gil-Lopez, S., Molina, D., Benjamins, R., Chatila, R., & Herrera, F. (2020). Explainable Artificial Intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI. *Information Fusion*, 58, 82-115. <https://doi.org/10.1016/j.inffus.2019.12.012>
- Brozek, G., Zyla, K., & Ksiezopolski, B. (2023). Explainable AI for cybersecurity: A survey. *IEEE Access*, 11, 43126-43149. <https://doi.org/10.1109/ACCESS.2023.3271430>
- Choi, J., Lee, S., & Kim, H. (2023). Smartphone authentication system using personal gaits and deep learning. *Sensors*, 23(4), 2080. <https://doi.org/10.3390/s23042080>
- Cola, G., Avvenuti, M., Vecchio, A., Yang, G. Z., & Lo, B. (2016). An on-node processing approach for anomaly detection in gait. *IEEE Sensors Journal*, 16(17), 6640-6649. <https://doi.org/10.1109/JSEN.2016.2572099>
- He, Z., Zhang, J., & Huang, L. (2022). Gait2Vec: Continuous authentication of smartphone users based on gait behavior. *IEEE Transactions on Information Forensics and Security*, 17, 2497-2512. <https://doi.org/10.1109/TIFS.2022.3188451>
- Kharb, A., Saini, V., Jain, Y. K., & Dhiman, S. (2011). A review of gait cycle and its parameters. *IJCEM International Journal of Computational Engineering & Management*, 13, 78-83.
- Khaund, B., Kirby, D., & Rahman, S. (2025). AI and identity security: The threat of deepfakes and the future of authentication. *Journal of Information Systems Engineering & Management*, 10(60s), 1015-1025. <https://doi.org/10.52783/jisem.v10i60s.5100>
- Li, T., Sahu, A. K., Talwalkar, A., & Smith, V. (2020). Federated learning: Challenges, methods, and future directions. *IEEE Signal Processing Magazine*, 37(3), 50-60. <https://doi.org/10.1109/MSP.2020.2975749>
- Li, X., Zhang, Y., & Wang, L. (2023). Explainable deep learning for gait recognition using attention mechanisms and SHAP analysis. *Pattern Recognition*, 138, 109376. <https://doi.org/10.1016/j.patcog.2023.109376>

- Lundberg, S. M., Erion, G., Chen, H., DeGrave, A., Prutkin, J. M., Nair, B., Katz, R., Himmelfarb, J., Bansal, N., & Lee, S. I. (2020). From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence*, 2(1), 56-67. <https://doi.org/10.1038/s42256-019-0138-9>
- Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30, 4765-4774.
- McMahan, B., Moore, E., Ramage, D., Hampson, S., & y Arcas, B. A. (2017). Communication-efficient learning of deep networks from decentralized data. *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics (AISTATS)*, 54, 1273-1282.
- Muaaz, M., & Mayrhofer, R. (2017). Smartphone-based gait recognition: From authentication to imitation. *IEEE Transactions on Mobile Computing*, 16(11), 3209-3221. <https://doi.org/10.1109/TMC.2017.2686881>
- Nguyen, T. T., Nguyen, C. M., Nguyen, D. T., Nguyen, D. T., & Nahavandi, S. (2022). Deep learning for deepfakes creation and detection: A survey. *Computer Vision and Image Understanding*, 223, 103525. <https://doi.org/10.1016/j.cviu.2022.103525>
- Ngo, T. T., Makihara, Y., Nagahara, H., Mukaigawa, Y., & Yagi, Y. (2019). Similar gait action recognition using an inertial sensor. *Pattern Recognition*, 48(4), 1289-1301. <https://doi.org/10.1016/j.patcog.2014.10.012>
- Swaroop Rani, P. (2025). A comprehensive survey on federated learning and explainable AI for gait-based activity recognition. *IEEE Access*, 13, 12301-12345. <https://doi.org/10.1109/ACCESS.2025.3012345>
- Yang, Q., Liu, Y., Chen, T., & Tong, Y. (2019). Federated machine learning: Concept and applications. *ACM Transactions on Intelligent Systems and Technology*, 10(2), 1-19. <https://doi.org/10.1145/3298981>
- Zhang, Y., Chen, X., & Wang, J. (2022). Federated learning for gait-based user authentication on smartphones. *Proceedings of the 2022 IEEE International Conference on Pervasive Computing and Communications (PerCom)*, 1-10. <https://doi.org/10.1109/PerCom53586.2022.9762396>