

PROPOSAL SKRIPSI NON KELAS

VERIFIKASI GAIT EKSPLISIT UNTUK AUTENTIKASI AMAN MENGUNAKAN EXPLAINABLE FEDERATED LEARNING

EXPLICIT GAIT VERIFICATION FOR SECURE AUTHENTICATION USING EXPLAINABLE FEDERATED LEARNING

Topik: Artificial Intelligence

2602077736 Dave Tjong Computer Science Alam Sutera / 081373417303



BINUS University
2026

Diperiksa oleh

D3690-Derwin Suhartono

DAFTAR ISI

Table of Contents

DAFTAR ISI	2
BAB 1. PENDAHULUAN	3
BAB 2. TINJAUAN PUSTAKA	7
BAB 3. METODE PELAKSANAAN	12
DAFTAR PUSTAKA.....	17

BAB 1. PENDAHULUAN

1.1 Latar Belakang

Metode autentikasi konvensional seperti password, PIN, dan biometrik statis (wajah, sidik jari, suara) semakin rentan terhadap serangan digital modern. Teknologi generative AI mampu memalsukan wajah dan suara secara realistis melalui deepfake dengan tingkat akurasi yang mengkhawatirkan (Khaund et al., 2025). Serangan deepfake telah berhasil menembus sistem autentikasi biometrik pada berbagai kasus, termasuk pembobolan rekening bank dan pencurian identitas (Nguyen et al., 2022). Situasi ini menciptakan kebutuhan mendesak akan metode autentikasi yang lebih robust dan sulit dipalsukan.

Autentikasi berbasis gait menawarkan pendekatan alternatif yang menjanjikan untuk mengatasi kelemahan biometrik statis. Penelitian dalam bidang biomechanics menunjukkan bahwa gait memiliki tiga keunggulan utama sebagai biometrik: (1) karakteristik unik untuk setiap individu yang dipengaruhi oleh struktur tulang, massa otot, dan kebiasaan motorik (Kharb et al., 2011), (2) bersifat kontinu dan dapat dimonitor secara pasif tanpa interaksi eksplisit pengguna, dan (3) sulit ditiru secara presisi bahkan dengan latihan intensif (Muaaz & Mayrhofer, 2017). Berbeda dengan biometrik statis yang dapat dipalsukan melalui foto, rekaman, atau model generatif, pola gait memerlukan simulasi kompleks terhadap dinamika gerakan tubuh yang melibatkan multiple sensor dan temporal consistency, menjadikannya lebih resisten terhadap spoofing attacks. Data gait dapat diperoleh secara non-intrusif melalui sensor accelerometer dan gyroscope yang telah tersedia pada hampir semua smartphone dan wearable devices modern.

Namun, penggunaan data gait untuk autentikasi menimbulkan dua tantangan kritis yang harus diatasi. Pertama, masalah privasi data. Data sensor gait mengandung informasi sensitif tentang identitas dan aktivitas pengguna yang dapat dieksploitasi untuk profiling atau tracking (Brožek et al., 2023). Pengumpulan data secara terpusat pada server pusat meningkatkan risiko kebocoran data dan single point of failure. Kedua, masalah transparansi model. Model deep learning yang digunakan untuk autentikasi bersifat black-box, sehingga sulit diaudit dan diverifikasi keputusannya (Lundberg & Lee, 2017). Kurangnya interpretabilitas membuat sistem rentan terhadap decision-making berdasarkan artefak data atau noise, bukan karakteristik biologis yang sesungguhnya.

Federated Learning (FL) menawarkan solusi untuk masalah privasi dengan melatih model secara terdistribusi di perangkat pengguna tanpa mengirimkan data mentah ke server pusat (McMahan et al., 2017). Dalam konteks autentikasi gait, FL memungkinkan setiap smartphone melatih model lokal menggunakan data gait pemiliknya, kemudian hanya mengirimkan parameter model, bukan data mentah, ke server untuk agregasi. Pendekatan ini mengurangi risiko kebocoran data dan menjaga privasi pengguna (Yang et al., 2019).

Sementara itu, Explainable AI (XAI) memberikan transparansi dengan mengidentifikasi fitur gait mana yang berkontribusi terhadap keputusan autentikasi (Arrieta et al., 2020). Metode seperti SHAP (SHapley Additive exPlanations) dapat menganalisis kontribusi setiap fitur sensor terhadap prediksi model, memungkinkan validasi bahwa sistem mengandalkan karakteristik biologis yang relevan, bukan pola spurious (Lundberg & Lee, 2017).

Studi ini mengintegrasikan gait-based authentication, Federated Learning, dan Explainable AI dalam satu sistem komprehensif. Integrasi ini bertujuan menghasilkan sistem autentikasi yang aman, privacy-preserving, dan dapat dijelaskan secara transparan. Arsitektur CNN-LSTM digunakan untuk mengekstraksi pola spasial dan temporal dari data gait, sementara algoritma FedAvg mengelola pelatihan terdistribusi, dan SHAP menganalisis kontribusi fitur dalam pengambilan keputusan.

1.2 Rumusan Masalah

Penelitian ini menjawab tiga pertanyaan penelitian utama:

1. **RQ1 (Effectiveness):** Seberapa efektif gait sebagai metode autentikasi berdasarkan metrik accuracy, precision, recall, F1-score, False Acceptance Rate (FAR), False Rejection Rate (FRR), dan Equal Error Rate (EER)?
2. **RQ2 (Privacy-Performance Trade-off):** Bagaimana trade-off antara privasi dan performa ketika menggunakan Federated Learning dibandingkan pelatihan terpusat, terutama dalam kondisi data non-IID (non-independent and identically distributed)?
3. **RQ3 (Explainability):** Bagaimana SHAP dapat mengidentifikasi fitur gait yang paling berkontribusi terhadap keputusan autentikasi, serta memastikan model tidak bergantung pada artefak atau noise?

1.3 Ruang Lingkup

Ruang lingkup penelitian ini adalah:

1. Penelitian ini berfokus pada pengembangan sistem autentikasi berbasis gait menggunakan sensor smartphone (accelerometer dan gyroscope 3-axis).
2. Penelitian menggunakan dataset yang dikumpulkan sendiri dari 50–100 partisipan dewasa sehat dengan empat posisi smartphone berbeda (pocket kiri, pocket kanan, tangan kiri dan tangan kanan).
3. Penelitian menerapkan arsitektur CNN-LSTM untuk ekstraksi fitur spasial-temporal dari data gait.
4. Penelitian mengimplementasikan Federated Learning menggunakan algoritma FedAvg untuk privacy-preserving training.
5. Penelitian menggunakan SHAP (SHapley Additive exPlanations) untuk analisis explainability dan identifikasi fitur penting.
6. Evaluasi dilakukan menggunakan authentication metrics (accuracy, precision, recall, F1-score, FAR, FRR, EER) dan FL performance metrics (convergence rate, communication cost).
7. Pengumpulan data dilakukan di indoor flat corridor dengan kecepatan berjalan natural dan durasi 90-100 detik per partisipan.

Ruang lingkup yang tidak termasuk dalam penelitian ini adalah:

1. Penelitian ini tidak mencakup biometrik lain seperti wajah, suara, sidik jari, atau iris.

2. Penelitian ini tidak menggunakan video-based gait recognition atau data dari wearable devices selain smartphone.
3. Penelitian ini tidak mengembangkan algoritma Federated Learning baru dan hanya menggunakan FedAvg standar.
4. Penelitian ini tidak menerapkan teknik privacy enhancement kompleks seperti differential privacy atau homomorphic encryption.
5. Penelitian ini tidak mencakup adversarial attacks seperti gradient-based attacks atau model poisoning.
6. Penelitian ini tidak mencakup variasi lingkungan seperti outdoor walking, stairs, slopes, atau extreme speed variations.
7. Penelitian ini merupakan proof-of-concept dengan offline evaluation, bukan live deployment system pada smartphone.

1.4 Tujuan dan Manfaat

Adapun tujuan dari penelitian ini adalah:

1. Mengevaluasi efektivitas gait sebagai biometrik untuk autentikasi dengan target performance EER < 5% dan accuracy > 90%.
2. Membandingkan performa Federated Learning dengan pelatihan terpusat untuk mengukur privacy-performance trade-off.
3. Menganalisis dampak distribusi data non-IID terhadap konvergensi dan akurasi model federated.
4. Mengidentifikasi fitur gait yang paling berkontribusi terhadap keputusan autentikasi menggunakan SHAP.
5. Memvalidasi bahwa model menggunakan karakteristik biologis yang relevan, bukan artefak data atau noise.

Adapun manfaat dari penelitian ini adalah:

1. Menyediakan evaluasi komprehensif integrasi Federated Learning dan Explainable AI pada sistem gait-based authentication sebagai kontribusi metodologis.
2. Menjadi referensi untuk penelitian autentikasi biometrik perilaku dengan fokus privacy preservation dan interpretabilitas model.
3. Menyediakan baseline metrik evaluasi (FAR, FRR, EER, convergence rate) untuk penelitian serupa di masa depan.
4. Menunjukkan potensi gait sebagai alternatif autentikasi yang lebih tahan terhadap deepfake attacks.
5. Membuktikan kelayakan teknis Federated Learning untuk sistem autentikasi berbasis sensor pada perangkat mobile.
6. Meningkatkan kepercayaan pengguna terhadap AI-based authentication melalui transparansi model.
7. Memberikan fondasi untuk pengembangan sistem autentikasi privacy-preserving pada smartphone.

1.5 Metodologi

Penelitian ini menggunakan pendekatan eksperimental kuantitatif untuk mengembangkan dan mengevaluasi sistem autentikasi gait yang mengintegrasikan Federated Learning dan Explainable AI. Metodologi penelitian mengadopsi dan memperluas protokol yang telah divalidasi oleh Choi et al. (2023) dengan penambahan komponen privacy preservation dan explainability.

A. Kerangka Penelitian

Penelitian dilakukan dalam tiga fase utama:

1. Development Phase

- Pengembangan aplikasi Android untuk data collection
- Implementasi arsitektur CNN-LSTM untuk feature extraction
- Setup Federated Learning framework menggunakan Flower library
- Integrasi SHAP untuk explainability analysis

2. Evaluation Phase

- Pengumpulan data gait dari 50–100 partisipan
- Eksperimen dalam lima skenario berbeda (baseline, FL vs centralized, non-IID analysis, multi-position robustness, SHAP analysis)
- Evaluasi menggunakan authentication metrics dan FL performance metrics

3. Analysis & Documentation

- Statistical analysis hasil eksperimen
- Interpretability validation (verifikasi SHAP features align dengan gait biomechanics)
- Comparative analysis dan benchmarking
- Penulisan thesis dan dokumentasi

B. Target Performance

Berdasarkan literature review dan preliminary analysis, penelitian ini menetapkan target performance sebagai berikut:

1. Equal Error Rate (EER) $< 5\%$
2. Accuracy $> 90\%$
3. Performance degradation FL vs centralized $< 5\%$
4. Convergence dalam 50 communication rounds

Detail metodologi pengumpulan data, pengembangan sistem, dan evaluasi dijelaskan secara komprehensif pada Bab 3.

BAB 2. TINJAUAN PUSTAKA

2.1 Teori yang berkaitan dengan penelitian

2.1.1 Gait-Based Authentication

Gait adalah pola berjalan yang unik untuk setiap individu, dipengaruhi oleh kombinasi kompleks struktur tulang, massa otot, distribusi berat badan, dan kebiasaan motorik (Kharb et al., 2011). Penelitian biomechanics menunjukkan bahwa gait cycle (satu siklus lengkap dari heel strike hingga heel strike berikutnya pada kaki yang sama) mengandung karakteristik temporal dan spasial yang dapat digunakan untuk identifikasi individu (Muaaz & Mayrhofer, 2017).

Dalam konteks autentikasi berbasis sensor, data gait diperoleh melalui accelerometer dan gyroscope yang mengukur percepatan linear dan kecepatan angular pada tiga sumbu (x, y, z). Sensor inersial ini mampu menangkap micro-movements dan subtle variations dalam pola berjalan yang sulit ditiru secara manual (Ngo et al., 2019). Keunggulan gait sebagai biometrik meliputi: (1) non-intrusive data collection tanpa interaksi eksplisit, (2) continuous authentication selama pengguna berjalan, dan (3) resilience terhadap spoofing attacks yang memerlukan simulasi kompleks dinamika tubuh (Cola et al., 2016).

2.1.2 Federated Learning

Federated Learning adalah paradigma machine learning terdistribusi yang memungkinkan pelatihan model secara kolaboratif tanpa sentralisasi data (McMahan et al., 2017). Dalam FL, setiap client (perangkat pengguna) melatih model lokal menggunakan data lokalnya, kemudian hanya mengirimkan parameter model, bukan data mentah, ke server pusat untuk agregasi.

FedAvg (Federated Averaging) adalah algoritma agregasi paling umum digunakan dalam FL (McMahan et al., 2017). Algoritma ini bekerja dengan weighted average terhadap parameter model lokal dari multiple clients, di mana weight ditentukan oleh jumlah data training pada setiap client. Proses iteratif ini diulang selama multiple communication rounds hingga model konvergen.

Tantangan utama FL meliputi: (1) data non-IID distribution (data tidak terdistribusi identically and independently across clients), (2) communication cost yang tinggi untuk transfer parameter model, dan (3) convergence yang lebih lambat dibanding centralized training (Li et al., 2020). Dalam konteks gait authentication, FL

menawarkan privacy benefit signifikan dengan menjaga data gait tetap berada di perangkat pengguna (Yang et al., 2019).

2.1.3 Explainable AI untuk Autentikasi

Explainable AI (XAI) bertujuan membuat decision-making process model AI lebih transparan dan interpretable (Arrieta et al., 2020). Dalam sistem autentikasi, XAI penting untuk: (1) validasi bahwa model menggunakan features yang relevan secara biologis, (2) deteksi potential biases atau reliance pada artefak data, dan (3) building trust dengan memberikan justification terhadap authentication decisions (Brožek et al., 2023).

SHAP (SHapley Additive exPlanations) adalah metode model-agnostic XAI yang menggunakan konsep Shapley value dari cooperative game theory untuk menghitung kontribusi setiap fitur terhadap prediksi model (Lundberg & Lee, 2017). SHAP memberikan consistency guarantees dan local accuracy, menjadikannya cocok untuk menganalisis model deep learning yang kompleks seperti CNN-LSTM (Lundberg et al., 2020).

Dalam konteks gait authentication, SHAP dapat mengidentifikasi sensor axes mana (e.g., accelerometer-y untuk vertical movement, gyroscope-z untuk rotational movement) yang paling berkontribusi terhadap user verification, serta temporal windows mana dalam gait cycle yang paling discriminative (Choi et al., 2023).

2.2 State of the Art

2.1.1 Smartphone Authentication System Using Personal Gaits and Deep Learning (Choi et al., 2023)

Choi et al. (2023) mengembangkan sistem autentikasi smartphone berbasis gait menggunakan Convolutional Neural Network (CNN) untuk mengatasi keterbatasan dataset publik yang dikumpulkan dari fixed sensor positions. Penelitian ini melibatkan 10 partisipan dengan pengumpulan data gait dari empat posisi smartphone berbeda (pocket kiri/kanan, tangan kiri/kanan) menggunakan accelerometer dan gyroscope 3-axis pada sampling rate 50 Hz. Data preprocessing meliputi linear interpolation, Butterworth low-pass filter (cutoff 20 Hz), window segmentation (1.8 detik dengan 50% overlap), dan Z-score normalization. Model CNN yang diimplementasikan menggunakan TensorFlow Lite untuk on-device training dan authentication.

Hasil evaluasi menunjukkan performa yang solid dengan average accuracy 91.76%, precision 91.02%, recall 92.83%, dan F1-score 91.81%. Authentication time

mencapai 1.8 detik, empat kali lebih cepat dibanding penelitian sebelumnya yang membutuhkan 7 detik. Sistem terbukti dapat mengenali legitimate users meskipun smartphone position berubah-ubah, menunjukkan robustness terhadap real-world usage scenarios.

Namun, penelitian ini memiliki beberapa keterbatasan signifikan. Sample size hanya 10 partisipan yang insufficient untuk statistical validation yang robust. Model hanya menggunakan CNN tanpa recurrent layers untuk menangkap temporal dependencies dalam gait cycle. Training dilakukan secara terpusat tanpa mekanisme privacy protection, tidak ada analisis explainability untuk mengidentifikasi fitur gait yang berkontribusi terhadap keputusan, dan evaluasi hanya menggunakan accuracy-based metrics tanpa authentication-specific metrics seperti FAR, FRR, atau EER. Penelitian kami mengadopsi preprocessing pipeline dan multi-position data collection strategy dari Choi et al., namun menambahkan larger sample size (50–100 users), temporal modeling dengan LSTM layers, privacy preservation melalui Federated Learning, explainability analysis menggunakan SHAP, dan authentication-specific metrics.

2.1.2 A Comprehensive Survey on Federated Learning and Explainable AI for Gait-Based Activity Recognition (Swaroop Rani, 2025)

Swaroop Rani (2025) melakukan comprehensive survey terhadap integrasi Federated Learning dan Explainable AI dalam gait-based activity recognition, menganalisis papers dari 2019–2024 yang dipublikasikan di top-tier journals seperti IEEE TNNLS, IEEE IoT Journal, dan ACM Computing Surveys. Survey ini membandingkan lima FL methods (FedAvg, FedProx, FedBN, Personalized FL, Hierarchical FL) dan lima XAI techniques (SHAP, LIME, Grad-CAM, Attention-based XAI, Hybrid Neuro-Fuzzy models) dengan evaluasi berdasarkan model accuracy, privacy preservation score, interpretability level, dan computational cost.

Findings menunjukkan bahwa Hierarchical FL combined dengan Hybrid XAI mencapai highest accuracy (93.1%) dan strongest privacy score (0.91), meskipun dengan computational cost yang lebih tinggi. FedAvg sebagai baseline method mencapai accuracy 88.5% dengan privacy score 0.85, sementara Personalized FL mencapai accuracy 92.5%. Survey mengidentifikasi bahwa privacy-preserving FL dapat mencapai accuracy mendekati centralized models dengan degradation kurang dari 5%. Key challenges yang diidentifikasi meliputi communication efficiency, computational overhead, dan terbatasnya dataset yang sudah dipartisi untuk federated scenarios.

Meskipun comprehensive, survey ini bersifat theoretical tanpa eksperimen empiris baru, dan existing datasets yang dianalisis kurang federated partitions untuk realistic FL research. Banyak dataset gait menggunakan vision-based data yang kurang applicable untuk smartphone sensors, serta kurangnya standardized evaluation frameworks untuk FL-XAI integration. Penelitian kami mengimplementasikan rekomendasi dari survey ini dengan menggunakan FedAvg sebagai baseline FL algorithm (terbukti efektif), mengadopsi SHAP untuk XAI analysis, mengatasi gap dataset dengan self-collected sensor-based data, dan menyediakan empirical evaluation yang comprehensive dengan authentication-specific metrics, sehingga menjadi salah satu implementasi empiris pertama yang memvalidasi findings dari survey Swaroopa Rani.

2.1.3 Gait2Vec: Continuous Authentication of Smartphone Users Based on Gait Behavior (He et al., 2022)

He et al. (2022) mengembangkan feature extractor berbasis transfer learning bernama Gait2Vec untuk gait authentication yang robust terhadap variasi sensor position, walking speed, dan environmental scenarios. Penelitian melibatkan 21 subjects (usia 22–48 tahun) dengan pengumpulan data dalam weakly constrained conditions dimana partisipan bebas menempatkan smartphone di pants pocket, jacket pocket, atau bag. Data dikumpulkan dalam dua scenarios dengan multiple sessions dari March hingga June (33–78 menit total per subject) pada sampling frequency 100 Hz yang kemudian di-downsample ke 50 Hz. Transfer learning approach melibatkan pre-training model pada user identification task (multi-class classification), kemudian transfer feature extractor untuk user authentication task (binary classification).

Model architecture menggunakan 3 Conv1D layers dengan batch normalization, max pooling, dan dropout sebagai Gait2Vec feature extractor. Hasil evaluasi menunjukkan bahwa 6-axis data (accelerometer + gyroscope) mencapai accuracy tertinggi 97.24% pada user identification, dibanding accelerometer only (96.92%) atau gyroscope only (93.62%). Multi-scenario training menghasilkan accuracy 94.27%, significantly better dibanding single-scenario training (85.5% untuk scenario 1, 88.84% untuk scenario 2). Pada user authentication, fully connected layers classifier mencapai performance terbaik dengan accuracy 99.98%, recall 99.98%, precision 99.97%, dan F1-score 99.98%, outperforming KNN (99.87%) dan SVM (97.87%) classifiers.


Keterbatasan penelitian mencakup moderate sample size (21 subjects), tidak menggunakan Federated Learning atau privacy-preserving techniques, tidak ada

explainability analysis menggunakan SHAP atau XAI methods, dan tidak melaporkan authentication-specific metrics seperti FAR, FRR, atau EER yang critical untuk security evaluation. Data collection juga primarily indoor dengan kurangnya outdoor environmental variations. Penelitian kami mengadopsi multi-position data collection approach dan 6-axis sensor data (accelerometer + gyroscope) dari He et al., extend CNN architecture dengan LSTM untuk temporal modeling, namun menambahkan critical missing components: Federated Learning untuk privacy preservation, SHAP analysis untuk explainability, authentication-specific metrics (FAR, FRR, EER), dan larger sample size (50–100 users) untuk statistical validity yang lebih kuat.

BAB 3. METODE PELAKSANAAN

3.1 Kerangka Berpikir

Kerangka berpikir penelitian ini menggambarkan tahapan sistematis untuk mengembangkan dan mengevaluasi sistem autentikasi gait berbasis Federated Learning dan Explainable AI. Berikut adalah flowchart kerangka berpikir penelitian:



Gambar 3.1 Flowchart Kerangka Berpikir Penelitian

3.2 Metode Penelitian

Metode penelitian ini menguraikan secara detail setiap tahapan yang telah digambarkan dalam kerangka berpikir di atas.

3.2.1 Pengumpulan Data Gait

Pengembangan Aplikasi Android:

Aplikasi mobile dikembangkan menggunakan Android Studio dengan fitur real-time sensor data capture dari accelerometer dan gyroscope pada sampling rate 50 Hz. Aplikasi menyimpan data dalam format CSV dengan metadata user ID, posisi smartphone, trial number, dan timestamp. Interface aplikasi dirancang sederhana untuk memudahkan partisipan melakukan self-recording tanpa bantuan researcher.

Rekrutmen Partisipan:

Target penelitian adalah 50–100 partisipan dewasa sehat berusia 18–60 tahun yang direkrut melalui campus announcements, social media, dan snowball sampling. Sample size ditentukan berdasarkan power analysis dengan significance level $\alpha = 0.05$, statistical power $1 - \beta = 0.80$, dan effect size $d = 0.5$ untuk mendeteksi perbedaan 2.5% accuracy antara FL vs centralized. Setiap partisipan menandatangani informed consent form.

Protokol Pengumpulan Data:

Data gait dikumpulkan di indoor flat corridor sepanjang 20 meter. Setiap partisipan melakukan walking trials dengan smartphone ditempatkan di empat posisi berbeda: pocket kanan, pocket kiri, tangan kanan, dan tangan kiri. Untuk setiap posisi, partisipan berjalan bolak-balik (round trip = 40 meter) sebanyak 2 kali dengan kecepatan natural. Total durasi recording per partisipan adalah sekitar 90–100 detik, menghasilkan dataset berukuran sekitar 1.46 MB per partisipan.

Preprocessing Data:

Data mentah melalui empat tahap preprocessing: (1) Linear interpolation untuk mengompensasi missing data points dengan error 0.5–1 ms, (2) Butterworth low-pass filter dengan cutoff frequency 20 Hz untuk noise removal, (3) Window segmentation dengan window size 1.8 detik (90 samples pada 50 Hz) dan 50% overlap untuk meningkatkan jumlah sampel, dan (4) Z-score normalization per sensor axis untuk standardisasi. Output preprocessing adalah time series dengan shape (90 timesteps, 6 channels) yang terdiri dari accelerometer x/y/z dan gyroscope x/y/z. Dataset kemudian di-split menjadi training set (70%), validation set (15%), dan test set (15%) dengan stratified splitting per user untuk mencegah data leakage.

3.2.2 Pengembangan Model

Desain Arsitektur CNN-LSTM:

Model hybrid CNN-LSTM dirancang untuk mengekstraksi fitur spasial dan temporal dari data gait. CNN layers terdiri dari dua convolutional blocks, masing-masing mengandung Conv1D layer (filters=64 dan 128, kernel_size=5), MaxPooling1D (pool_size=2), dan Dropout (rate=0.3) untuk regularization. Output CNN kemudian diproses oleh LSTM layer (units=128) untuk menangkap temporal dependencies dalam gait cycle. Final layers terdiri dari Dense layer (64 units dengan ReLU activation, dropout=0.5) dan output layer (softmax activation untuk num_users classes). Model di-compile dengan optimizer Adam (learning rate=0.001), loss function categorical crossentropy, dan training selama maksimal 50 epochs dengan early stopping (patience=10, monitor='val_loss').

Implementasi Federated Learning:

Federated Learning diimplementasikan menggunakan Flower framework versi 1.5+ dengan algoritma FedAvg. Konfigurasi FL meliputi: total clients = 50–100 (1 user = 1 client), clients per round K divariasikan (10, 25, 50), local epochs E divariasikan (1, 5, 10), dan total communication rounds = 50–100 tergantung convergence. Server mengagregasi model parameters menggunakan weighted averaging formula:

$$w_{global} = \sum_{k=1}^k \frac{n_k}{N} W_k$$

dimana W_k adalah local model parameters dari client k , n_k adalah jumlah training samples pada client k , dan n adalah total training samples. Privacy dijaga dengan zero raw data transfer, hanya model parameters yang dikirim antara clients dan server.

Non-IID Data Simulation:

Untuk mensimulasikan realistic federated scenarios, data dipartisi dengan controlled heterogeneity menggunakan Dirichlet distribution. Concentration parameter α divariasikan: $\alpha = \infty$ (IID baseline), $\alpha = 1.0$ (moderate non-IID), $\alpha = 0.5$ (strong non-IID), dan $\alpha = 0.1$ (very strong non-IID). Implementasi menggunakan $\text{Dirichlet}(\alpha)$ untuk mengalokasikan samples dari setiap class ke clients dengan controlled imbalance, memungkinkan analisis dampak data heterogeneity terhadap convergence rate dan final model accuracy.

Integrasi SHAP untuk Explainability:

SHAP (SHapley Additive exPlanations) diintegrasikan untuk post-hoc analysis setelah model training. Workflow SHAP meliputi: (1) seleksi representative background data (100 instances dari training set), (2) komputasi Shapley values untuk test instances menggunakan SHAP library, (3) agregasi SHAP values across multiple users untuk identify consistent patterns. Output berupa global feature importance ranking (sensor axes berdasarkan average $|\text{SHAP value}|$), temporal importance heatmaps (critical timesteps dalam 1.8-second window), dan biomechanical validation (verifikasi bahwa top features align dengan gait biomechanics seperti accelerometer-y untuk vertical movement dan gyroscope-z untuk hip rotation).

3.2.3 Eksperimen dan Evaluasi

Penelitian melakukan lima skenario eksperimen untuk menjawab research questions.

Skenario 1: Baseline Evaluation

Centralized training dengan semua data untuk baseline performance. Model dilatih menggunakan gabungan dataset dari semua users tanpa federated partitioning. Evaluasi menggunakan accuracy, precision, recall, F1-score, FAR, FRR, dan EER pada test set. Hasil baseline menjadi reference untuk mengukur performance degradation pada federated scenarios.

Skenario 2: Perbandingan FL dengan Centralized

Perbandingan empat kondisi untuk evaluate privacy-performance trade-off: (A) Centralized baseline, (B) Federated dengan $K=10$ dan $E=5$, (C) Federated dengan $K=25$ dan $E=5$, dan (D) Federated dengan $K=50$ dan $E=1$. Metrik yang dibandingkan meliputi accuracy degradation, convergence rounds (jumlah rounds untuk mencapai 90% accuracy), dan communication cost (total data transfer = rounds $\times$ clients_per_round $\times$ model_size). Statistical significance testing menggunakan paired t-test untuk menguji hipotesis H2: performance degradation FL < 5%.

Skenario 3: Analisa Dampak Non-IID

Analisis dampak data heterogeneity dengan varying Dirichlet concentration parameter α (∞ , 1.0, 0.5, 0.1). Untuk setiap α value, FL training dilakukan dengan fixed configuration ($K=10$, $E=5$) dan convergence behavior dimonitor. Metrik yang dianalisis: convergence rate (rounds yang dibutuhkan untuk mencapai akurasi yang stabil), accuracy variance across clients (standard deviation dari client accuracies), dan correlation antara α value dengan performance metrics menggunakan Pearson correlation.

Skenario 4: Multi-Position Robustness

Validasi generalization across smartphone positions dengan train-test split berdasarkan posisi. Training set menggunakan data dari 3 posisi (pocket left, pocket right, hand left), test set menggunakan data dari unseen position (hand right). Evaluasi cross-position accuracy dan position-wise FAR/FRR untuk mengukur robustness.

Skenario 5: SHAP Feature Analysis

SHAP analysis pada trained model (centralized dan federated) untuk identifikasi important gait features. Output berupa feature importance rankings (top-10 sensor axes dan timesteps), temporal importance heatmaps (visualization critical phases dalam gait window), dan biomechanical alignment score (percentage of top-10 features yang align dengan expected biomechanical importance). Validasi dilakukan dengan membandingkan SHAP rankings dari centralized dengan federated models menggunakan Spearman correlation untuk mengukur konsistensi.

3.2.4 Analisis Hasil

Statistical Testing:

Hypothesis testing dilakukan untuk validate research questions. H1 testing (Effectiveness) menggunakan one-sample t-test dengan $H_0: EER \geq 5\%$ vs $H_1: EER < 5\%$ pada significance level $\alpha = 0.05$. H2 testing (FL Degradation) menggunakan paired t-test dengan $H_0: Degradation \geq 5\%$ vs $H_1: Degradation < 5\%$, dimana

$\text{degradation} = (\text{Acc_centralized} - \text{Acc_federated}) / \text{Acc_centralized} \times 100\%$. H3 testing (SHAP Biomechanical Alignment) menggunakan binomial test dengan $H_0: P(\text{alignment}) \leq 0.5$ vs $H_1: P(\text{alignment}) > 0.5$. Confidence intervals (95% CI) untuk semua reported metrics dihitung menggunakan bootstrap resampling dengan 1000 iterations. Effect size dihitung menggunakan Cohen's d untuk magnitude of differences dengan interpretation: small (0.2), medium (0.5), large (0.8).

Performance Comparison:

Comparative analysis dilakukan untuk benchmarking terhadap baseline dan state-of-the-art. Comparison table dibuat untuk summarize accuracy, EER, convergence rounds, communication cost, dan interpretability metrics across different configurations. Results dibandingkan dengan Choi et al. (2023) baseline (91.76% accuracy, 1.8s authentication time), Swaroopa Rani survey findings (FedAvg 88.5%, Hierarchical FL 93.1%), dan He et al. (2022) transfer learning approach (97.24% identification, 99.98% authentication).

Interpretability Validation:

SHAP feature importance results divalidasi dengan domain knowledge dari gait biomechanics literature. Top features yang expected: accelerometer-y (vertical movement dari ground reaction force), gyroscope-z (hip rotation around vertical axis), dan mid-stride timesteps (phase dengan most discriminative gait patterns). Biomechanical alignment score dihitung sebagai percentage of top-10 SHAP features yang match expected features. Visualization dibuat berupa SHAP summary plots, dependence plots, dan temporal heatmaps untuk facilitate interpretation.

DAFTAR PUSTAKA

- Arrieta, A. B., Díaz-Rodríguez, N., Del Ser, J., Bennetot, A., Tabik, S., Barbado, A., García, S., Gil-López, S., Molina, D., Benjamins, R., Chatila, R., & Herrera, F. (2020). *Explainable Artificial Intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI*. *Information Fusion*, 58, 82–115. <https://doi.org/10.1016/j.inffus.2019.12.012>
- Brożek, G., Żyła, K., & Księżopolski, B. (2023). *Explainable AI for cybersecurity: A survey*. *IEEE Access*, 11, 43126–43149. <https://doi.org/10.1109/ACCESS.2023.3271430>
- Choi, J., Lee, S., & Kim, H. (2023). *Smartphone authentication system using personal gaits and deep learning*. *Sensors*, 23(4), 2080. <https://doi.org/10.3390/s23042080>
- Cola, G., Avvenuti, M., Vecchio, A., Yang, G. Z., & Lo, B. (2016). *An on-node processing approach for anomaly detection in gait*. *IEEE Sensors Journal*, 16(17), 6640–6649. <https://doi.org/10.1109/JSEN.2016.2584702>
- Kharb, A., Saini, V., Jain, Y. K., & Dhiman, S. (2011). *A review of gait cycle and its parameters*. *IJCEM International Journal of Computational Engineering & Management*, 13, 78–83.
- Khaund, B., Kirby, D., & Rahman, S. (2025). *AI and identity security: The threat of deepfakes and the future of authentication*. *Journal of Information Systems Engineering & Management*, 10(60s), 1015–1030. <https://doi.org/10.52783/jisem.v10i60s.13259>
- Li, T., Sahu, A. K., Talwalkar, A., & Smith, V. (2020). *Federated learning: Challenges, methods, and future directions*. *IEEE Signal Processing Magazine*, 37(3), 50–60. <https://doi.org/10.1109/MSP.2020.2975749>
- Li, X., Zhang, Y., & Wang, J. (2023). *Explainable deep learning for gait recognition using attention mechanisms and SHAP analysis*. *Pattern Recognition*, 138, 109376. <https://doi.org/10.1016/j.patcog.2023.109376>

Lundberg, S. M., Erion, G., Chen, H., DeGrave, A., Prutkin, J. M., Nair, B., Katz, R., Himmelfarb, J., Bansal, N., & Lee, S. I. (2020). *From local explanations to global understanding with explainable AI for trees*. *Nature Machine Intelligence*, 2(1), 56–67. <https://doi.org/10.1038/s42256-019-0138-9>

Lundberg, S. M., & Lee, S. I. (2017). *A unified approach to interpreting model predictions*. In *Advances in Neural Information Processing Systems* (Vol. 30, pp. 4765–4774). Curran Associates, Inc.

McMahan, B., Moore, E., Ramage, D., Hampson, S., & y Arcas, B. A. (2017). *Communication-efficient learning of deep networks from decentralized data*. In *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics (AISTATS)* (Vol. 54, pp. 1273–1282). PMLR.

Muaaz, M., & Mayrhofer, R. (2017). *Smartphone-based gait recognition: From authentication to imitation*. *IEEE Transactions on Mobile Computing*, 16(11), 3209–3221. <https://doi.org/10.1109/TMC.2017.2686855>

Ngo, T. T., Makiyara, Y., Nagahara, H., Mukaigawa, Y., & Yagi, Y. (2019). *Similar gait action recognition using an inertial sensor*. *Pattern Recognition*, 48(4), 1289–1301. <https://doi.org/10.1016/j.patcog.2014.10.012>

Nguyen, T. T., Nguyen, C. M., Nguyen, D. T., Nguyen, D. T., & Nahavandi, S. (2022). *Deep learning for deepfakes creation and detection: A survey*. *Computer Vision and Image Understanding*, 223, 103525. <https://doi.org/10.1016/j.cviu.2022.103525>

Yang, Q., Liu, Y., Chen, T., & Tong, Y. (2019). *Federated machine learning: Concept and applications*. *ACM Transactions on Intelligent Systems and Technology*, 10(2), 1–19. <https://doi.org/10.1145/3298981>

Zhang, Y., Chen, X., & Wang, L. (2022). *Federated learning for gait-based user authentication on smartphones*. In *Proceedings of the 2022 IEEE International Conference on Pervasive Computing and Communications Workshops (PerCom Workshops)* (pp. 512–517). IEEE. <https://doi.org/10.1109/PerComWorkshops53856.2022.9767407>